

Determinantes de las lesiones en jugadores profesionales de fútbol: un modelo de regresión logística

Samuel Arbeález Abraham Bohorquez Departamento de Ingeniería Industrial, Universidad de los Andes,
Bogotá, Colombia
{s.arbelaez, a.bohorquez}@uniandes.edu.co

Resumen—Este estudio identifica y cuantifica los factores físicos, psicológicos, clínicos y de hábitos asociados a la probabilidad de lesión en jugadores profesionales de fútbol, mediante un modelo de regresión logística binaria estimado sobre $n = 800$ observaciones y $p = 18$ covariables. La variable respuesta *Injury_Next_Season* es binaria y balanceada (50 %/50 %), lo que evita el uso de técnicas de remuestreo. Se aplicó un protocolo metodológico riguroso de siete etapas: (i) análisis exploratorio bivariado con pruebas t de Welch y χ^2 ; (ii) diagnóstico de multicolinealidad ($\kappa = 5,458$, $VIF_{\max} = 2,08$); (iii) selección de variables por eliminación regresiva guiada por AIC en seis pasos; (iv) cinco pruebas formales de especificación del enlace (Box-Tidwell, Pregibon, Stukel, RESET, Hosmer-Lemeshow), todas con $p > 0,15$; (v) análisis completo de residuos, influencia y sobredispersión; (vi) evaluación de términos de interacción con soporte teórico; y (vii) comparación con LASSO como especificación alternativa.

El modelo final incorpora 13 predictores y una interacción significativa Estrés $\times$ Sueño ($\hat{\beta} = -0,803$, $p = 0,029$, $\Delta AIC = -2,84$). Sus métricas son consistentemente altas: AUC = 0,9972, *accuracy* 98.1 %, Brier Score = 0,024 y pseudo- R^2 de Nagelkerke = 0,913. La validación cruzada estratificada de 10 particiones confirma la estabilidad del desempeño predictivo (AUC_{CV} = 0,991, IC 95 % [0,985, 0,997]).

Los factores de riesgo más fuertes son el tiempo de reacción lento (OR = 3,84, AME = +4,65 pp) y el estrés crónico (OR = 3,59, AME = +4,42 pp). Los protectores de mayor magnitud son el balance corporal (OR = 0,23, AME = -5,07 pp) y la adherencia al calentamiento (OR = 0,25, AME = -4,84 pp). La interacción significativa entre estrés y sueño constituye el hallazgo más novedoso: los datos son consistentes con un efecto modulador del sueño sobre la asociación entre estrés y riesgo de lesión, con implicaciones para el diseño de intervenciones preventivas, sujeto a validación en estudios con diseño experimental.

Index Terms—Regresión logística, GLM Bernoulli-logit, lesiones deportivas, *odds ratio*, efectos marginales promedio, validación cruzada, LASSO, interacción, medicina deportiva, prevención de lesiones.



1. INTRODUCCIÓN

Las lesiones musculoesqueléticas representan uno de los mayores desafíos del deporte profesional contemporáneo. En las principales ligas europeas de fútbol, los equipos pierden en promedio entre 150 y 200 días-jugador por temporada exclusivamente por causas lesionales, con costos directos que superan los diez millones de euros anuales en clubes de élite [1]. Más allá del impacto económico, las lesiones deterioran el rendimiento colectivo del equipo, interrumpen el desarrollo individual del deportista y pueden comprometer su carrera de manera irreversible. Desde una perspectiva de salud pública deportiva, la identificación precisa de los determinantes de la lesión constituye el primer paso para diseñar intervenciones preventivas basadas en evidencia y rentables en términos de recursos médicos.

La medicina del deporte contemporánea ha transitado desde los modelos monocausales —que atribuían la lesión a un único factor desencadenante— hacia marcos teóricos multifactoriales que integran, simultáneamente, la carga de entrenamiento y competición, el estado físico del deportista, los factores psicológicos, los hábitos de recuperación, el historial clínico previo y las características del entorno [2]. Este cambio paradigmático ha impulsado el uso de modelos estadísticos

multivariados capaces de cuantificar el efecto independiente de cada predictor, controlando simultáneamente por el resto de covariables.

En este contexto, la regresión logística binaria ocupa un lugar privilegiado en la epidemiología deportiva: su fundamento teórico dentro de la familia de modelos lineales generalizados (GLM) [3], la interpretabilidad directa de sus coeficientes en términos de *odds ratios* (OR) y efectos marginales promedio (AME), y la disponibilidad de herramientas diagnósticas formales la convierten en el instrumento analítico de referencia para estudios observacionales sobre incidencia de lesiones [4].

1.1. Contribuciones de este trabajo

Este trabajo contribuye en tres dimensiones complementarias. En primer lugar, estima un modelo multivariado que cuantifica el efecto independiente de doce predictores provenientes de cuatro dominios clínicamente relevantes: físico, psicológico, clínico e histórico. En segundo lugar, evalúa una interacción entre el nivel de estrés y las horas de sueño que, a nuestro conocimiento, no ha sido modelada explícitamente con este enfoque en la literatura de epidemiología deportiva. En tercer lugar, aplica un protocolo diagnóstico exhaustivo de

siete etapas que verifica rigurosamente todos los supuestos del modelo logístico antes de proceder a la interpretación sustantiva de los resultados.

1.2. Pregunta de investigación

¿Cuáles factores físicos, psicológicos, clínicos y de hábitos determinan la probabilidad de que un jugador profesional sufra una lesión durante la temporada siguiente, y con qué magnitud opera cada uno, controlando simultáneamente por el efecto de los demás?

1.3. Hipótesis estadísticas

A partir de la literatura biomecánica y epidemiológica especializada [5], [6], [7], [8], [9], se plantean hipótesis unilaterales para los predictores cuya dirección teórica es inequívoca, y bilaterales para el resto:

$$H_0^{(1)} : \beta_{\text{Stress}} = 0 \text{ vs. } H_1^{(1)} : \beta_{\text{Stress}} > 0, \quad (1)$$

$$H_0^{(2)} : \beta_{\text{Sleep}} = 0 \text{ vs. } H_1^{(2)} : \beta_{\text{Sleep}} < 0, \quad (2)$$

$$H_0^{(3)} : \beta_{\text{PrevInj}} = 0 \text{ vs. } H_1^{(3)} : \beta_{\text{PrevInj}} > 0, \quad (3)$$

$$H_0^{(4)} : \beta_{\text{Balance}} = 0 \text{ vs. } H_1^{(4)} : \beta_{\text{Balance}} < 0, \quad (4)$$

$$H_0^{(5)} : \beta_{\text{Warmup}} = 0 \text{ vs. } H_1^{(5)} : \beta_{\text{Warmup}} < 0. \quad (5)$$

La justificación de las direcciones unilaterales descansa en evidencia acumulada durante décadas: el estrés psicológico activa mecanismos de distracción atencional y deterioro del control motor [5], [9]; la privación de sueño deteriora los tiempos de reacción, la coordinación y la capacidad de recuperación muscular [7]; el historial de lesiones previas genera alteraciones neuromusculares persistentes y cicatrices que modifican la biomécanica del movimiento, elevando el riesgo de recurrencia [2]; y el balance postural junto con la adherencia al calentamiento han sido identificados como factores protectores consistentes en programas de prevención [8], [6].

2. DATOS Y ANÁLISIS EXPLORATORIO

2.1. Descripción del conjunto de datos

La base de datos contiene $n = 800$ observaciones de jugadores profesionales de fútbol, con 18 variables predictoras y una respuesta binaria. Las variables se agrupan en seis dominios:

- **Antropométrico:** Edad, Talla, Peso, IMC.
- **Carga competitiva:** horas de entrenamiento por semana, partidos jugados la temporada anterior, número de lesiones previas.
- **Capacidades físicas:** fuerza de rodilla, flexibilidad de isquiotibiales, tiempo de reacción, balance corporal, velocidad de sprint, agilidad.
- **Hábitos:** horas de sueño por noche, calidad nutricional, adherencia al calentamiento.
- **Posición:** portero, defensa, mediocampista, delantero.
- **Indicador de lesión:** Injury_Next_Season (binaria).

En la etapa de preprocesamiento, Talla y Peso fueron eliminados por su elevada colinealidad con IMC ($r_{\text{Peso,IMC}} = 0,85$,

Tabla 1: Estadísticos descriptivos de variables continuas ($n = 800$). La mayoría de las distribuciones son aproximadamente normales. El IMC presenta outliers superiores compatibles con jugadores de mayor masa muscular.

Variable	Media	DE	Mín	Máx
Age (años)	21.1	1.87	18	24
BMI (kg/m ²)	23.4	2.13	18.5	35.2
Training Hrs/Week	9.95	2.44	4.0	18.0
Matches Past Season	22.3	9.21	5	38
Previous Injury Count	1.53	1.18	0	6
Knee Strength Score	74.9	7.82	55	95
Hamstring Flexibility	79.2	8.14	55	98
Reaction Time (ms)	249	24.3	190	330
Balance Test Score	83.8	8.43	55	99
Sprint Speed (m/s)	5.95	0.49	4.5	7.2
Agility Score	78.3	8.91	53	99
Sleep Hours/Night	7.42	0.89	5.0	9.5
Stress Level Score	54.0	18.2	15	95
Nutrition Quality	74.4	10.1	45	98

$r_{\text{Talla,IMC}} = -0,50$). Incluir las tres variables simultáneamente inflaría la varianza de los estimadores sin aportar información adicional. La Tabla 1 presenta los estadísticos descriptivos de las variables continuas.

Fuente de los datos. El dataset fue obtenido del repositorio público Kaggle bajo el título *University Football Injury Prediction Dataset* [10], que compila información de 800 jugadores de fútbol universitario chino con seguimiento de 6 meses. El dataset ha sido utilizado recientemente en trabajos de aprendizaje automático interpretable [11].

Limitación por tamaño muestral. Con $n = 800$ observaciones y $p = 18$ covariables, la razón observación-parámetro en el modelo final ($n/k \approx 50$) es aceptable para regresión logística, pero se encuentra en el límite inferior recomendado para estudios epidemiológicos [12]. La muestra es insuficiente para detectar efectos pequeños ($|\text{OR}| < 1,3$) con potencia adecuada, y los estimadores de la cola de la distribución de probabilidades (zona de quasi-separación) son específicamente sensibles al tamaño muestral. El balance perfecto de clases (50 %/50 %) es una fortaleza en términos de estabilidad del umbral de decisión, pero es inusual en datos clínicos reales y podría reflejar un proceso de selección controlado en la construcción del dataset.

2.2. Variable respuesta y balance de clases

La variable `Injury_Next_Season` está perfectamente balanceada: 400 jugadores lesionados (50 %) y 400 no lesionados (50 %). Este balance tiene tres consecuencias metodológicas importantes. Primero, no se requieren técnicas de remuestreo como SMOTE, submuestreo de la clase mayoritaria ni ponderación diferencial de observaciones. Segundo, la *accuracy* del modelo nulo (que predice siempre la clase mayoritaria) es del 50 %, lo que proporciona una línea base exigente para evaluar el valor añadido del modelo. Tercero, las métricas estándar de clasificación —AUC, F1-Score, precision, recall— son interpretables sin ajustes por desbalance, aunque su interpretación sigue siendo condicionada al tamaño y composición de la muestra. La distribución equitativa sugiere además que el dataset fue construido con diseño de casos y controles, o que se trató de una selección representativa de jugadores con y sin lesión.

2.3. Distribución de las variables numéricas

El análisis de histogramas sobre los 800 jugadores revela formas bien comportadas en la mayoría de predictores, lo que anticipa un proceso de modelado estadísticamente robusto.

La **edad** se distribuye de manera prácticamente uniforme entre los 18 y los 24 años, reflejando una muestra de jugadores jóvenes en etapa de desarrollo o inicio de carrera profesional. Este rango estrecho limita la variabilidad de la edad y anticipa su probable falta de poder discriminatorio en el modelo multivariado.

El **IMC** sigue una curva aproximadamente normal centrada en 23 kg/m², dentro del rango saludable (18.5–25). Se observan outliers superiores entre 33 y 36 kg/m², compatibles con jugadores de mayor masa muscular o constituciones robustas típicas de ciertas posiciones (porteros y defensas centrales). Estos valores no implican necesariamente un estado nutricional deficiente en contexto atleta.

Las **horas de entrenamiento semanales** presentan sesgo positivo, con la mayoría de jugadores concentrada entre 8 y 12 h/semana, y una cola de casos que llega hasta 18 horas. Esta heterogeneidad es esperable en una muestra que combina jugadores de diferentes roles y equipos con distintos volúmenes de trabajo.

El **número de lesiones previas** muestra la distribución más sesgada del dataset, con moda en 0 y cola derecha extensa hasta 6 lesiones. El valor medio de 1.53 indica que la mayoría de los jugadores ya ha experimentado al menos una lesión a lo largo de su carrera, lo que subraya la importancia clínica de este historial como predictor.

Las variables de **capacidad física y hábitos** (fuerza de rodilla, balance, sueño, estrés, nutrición) siguen distribuciones aproximadamente normales, sin bimodalidad ni irregularidades que sugieran errores de captura o mezcla de subpoblaciones heterogéneas. No se identificaron distribuciones imposibles en ninguna variable, lo que confirma la calidad básica del dataset y su aptitud para el modelado.

Con respecto a los valores atípicos detectados mediante boxplots univariados, se observan outliers leves en estatura (algunos casos inferiores a 160 cm), peso (un caso cercano a 105 kg), IMC (valores entre 33 y 36), número de lesiones previas (6 lesiones acumuladas), horas de entrenamiento (17–18 h/semana) y horas de sueño (un caso aproximado a 5 horas y otro a 10 horas). Se decidió no eliminar estos valores en esta fase, dado que representan situaciones clínicamente reales y potencialmente informativas para el modelo. Su tratamiento formal se realiza en la Sección 8 mediante la distancia de Cook y el análisis de influencia.

2.4. Distribución de variables categóricas

La variable **Position** presenta cuatro categorías bien representadas, con entre 185 y 210 jugadores por posición. Este balance garantiza comparaciones estadísticamente fiables entre grupos en el modelo multivariado y descarta que la dummy de alguna posición esté subestimada. **Warmup_Routine_Adherence** registra aproximadamente 475 jugadores que adhieren a la rutina de calentamiento (aproximadamente el 59 %) frente a 325 que no lo hacen (aproximadamente el 41 %), con representación suficiente

Tabla 2: Diferencias de medias entre clases y significancia. †: $p < 0,001$ en ambas pruebas; n.s.: no significativa.

Variable	No les.	Les.	Δ	Sig.
Stress_Level	47.99	60.09	+12,10	†
Sleep_Hours	7.82	7.01	−0,81	†
Reaction_Time	238.82	260.03	+21,21	†
Balance_Score	87.26	80.41	−6,86	†
Agility_Score	81.79	74.89	−6,90	†
Knee_Strength	77.96	71.90	−6,06	†
Hamstring_Flex	82.21	76.10	−6,11	†
Nutrition_Score	78.23	70.54	−7,69	†
Previous_Inj	1.04	2.03	+0,99	†
Sprint_Speed	6.10	5.79	−0,31	†
Height_cm	177.80	177.02	−0,79	n.s.
BMI	23.20	23.55	+0,35	n.s.
Matches_Season	22.79	21.88	−0,91	n.s.
Training_Hrs	9.86	10.04	+0,18	n.s.
Age	21.09	21.18	+0,09	n.s.
Weight_kg	73.03	73.45	+0,42	n.s.
Warmup: 60.9 % vs. 39.1 %				†
Position: $\chi^2 = 2,42$, $p = 0,49$				n.s.

en ambas categorías para una estimación confiable del coeficiente asociado.

2.5. Análisis bivariado: variables numéricas versus lesión

Para cada variable continua se aplicaron la prueba t de Welch (comparación de medias con varianzas desiguales) y la prueba U de Mann-Whitney (alternativa no paramétrica, robusta ante desviaciones de la normalidad). Para las variables categóricas se aplicó la prueba χ^2 de independencia. La Tabla 2 consolida los resultados.

La Figura 1 ilustra las diferencias bivariadas mediante boxplots estratificados. El patrón es inequívoco: las variables asociadas al control neuromuscular, el estado psicológico y los hábitos presentan separación visual clara entre lesionados y no lesionados, mientras que las variables antropométricas y de carga muestran cajas prácticamente solapadas.

Los tres predictores con mayor diferencia absoluta de medias son: **Stress_Level** ($\Delta = +12,10$ puntos), **Reaction_Time** ($\Delta = +21,21$ ms) y **Nutrition_Quality** ($\Delta = -7,69$ puntos). El nivel de estrés de los jugadores lesionados es un 25 % más alto en términos relativos respecto a los no lesionados, y su tiempo de reacción promedio es 8.9 % más lento. Estas magnitudes son clínicamente relevantes y estadísticamente robustas: ambas pruebas —paramétrica y no paramétrica— entregan $p < 0,001$ en todos los casos marcados con †.

El análisis de la adherencia al calentamiento merece atención especial. Entre quienes *no calientan*, el 66.2 % se lesiona en la siguiente temporada; entre quienes *sí calientan*, solo el 39.1 % lo hace ($\chi^2 = 55,14$, $p < 0,0001$). Esta diferencia de 27 puntos porcentuales en la tasa de lesión es la mayor diferencia proporcional observada en el dataset, lo que posiciona al calentamiento como uno de los factores modificables más poderosos disponibles para intervención clínica.

La posición del jugador, en contraste, no muestra asociación significativa ($\chi^2 = 2,42$, $p = 0,49$). El porcentaje de lesión es similar entre porteros, defensas, mediocampistas y delanteros, sugiriendo que la distribución de carga física

y de riesgo es razonablemente equitativa entre posiciones en la población estudiada. Este hallazgo justifica la posterior eliminación de las dummies de posición durante la selección de variables.

2.6. Correlaciones entre predictores y con la variable respuesta

La Figura 2 presenta la matriz de correlaciones de Pearson sobre el conjunto completo de variables numéricas, incluyendo la respuesta.

El ranking de correlación absoluta con `Injury_Next_Season` es: Stress ($r = 0,530$), Sleep ($r = -0,511$), Balance ($r = -0,495$), Sprint ($r = -0,471$), Reaction_Time ($r = 0,471$), Knee ($r = -0,455$), Hamstring ($r = -0,450$), Nutrition ($r = -0,412$), Agility ($r = -0,394$), Previous_Injury ($r = 0,382$). La franja de correlaciones altas ($|r| > 0,38$) agrupa exactamente las diez variables que resultarán significativas en el modelo multivariado, lo que es consistente con la coherencia entre el análisis exploratorio y los resultados de estimación. En contraste, Height, BMI, Matches, Training, Age y Weight presentan correlaciones inferiores a $|r| < 0,056$, reforzando la evidencia bivariada de que estas variables no aportan información discriminatoria. En cuanto a colinealidad entre predictores, destacan dos pares con correlaciones elevadas: Peso-IMC ($r = 0,85$) y Talla-IMC ($r = -0,50$). Estas correlaciones son físicamente esperables, dado que el IMC se calcula como $\text{Peso}/\text{Talla}^2$, lo que introduce dependencia algebraica directa. Incluir las tres variables simultáneamente en el modelo generaría multicolinealidad severa e inflaría la varianza de los estimadores de estos coeficientes, por lo que se justifica conservar únicamente el IMC. El resto de correlaciones entre predictores se mantiene por debajo de $|r| = 0,30$, indicando una estructura de datos limpia en términos de independencia entre las covariables seleccionadas para el modelado.

2.7. Conclusiones del análisis exploratorio

El análisis exploratorio establece tres conclusiones que guían el modelado. Primera, existe un conjunto claramente diferenciado de diez predictores con asociación bivariada significativa y correlaciones con el target superiores a 0.38; estos serán los candidatos naturales del modelo. Segunda, las variables antropométricas básicas y de carga (edad, talla, peso, IMC, partidos y horas de entrenamiento) no muestran discriminación alguna y serán candidatas a eliminación. Tercera, la multicolinealidad detectada entre Peso, Talla e IMC obliga a conservar únicamente esta última antes de ajustar el modelo base.

3. ESPECIFICACIÓN DEL MODELO

3.1. Marco GLM Bernoulli-logit

Sea $Y_i \in \{0, 1\}$ el indicador de lesión del jugador i . Se asume:

$$Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{Bernoulli}(\mu_i), \quad i = 1, \dots, 800, \quad (6)$$

con función de enlace canónica logit:

$$g(\mu_i) = \log\left(\frac{\mu_i}{1 - \mu_i}\right) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}. \quad (7)$$

La relación varianza-media es $\text{Var}(Y_i | \mathbf{x}_i) = \mu_i(1 - \mu_i)$, determinada completamente por μ_i sin parámetro de dispersión adicional. Esta propiedad distingue la familia Bernoulli de la binomial general y de las familias de conteo, donde la sobredispersión es frecuente.

3.2. Justificación del enlace logit

El enlace logit es el canónico de la familia Bernoulli: maximiza la interpretabilidad computacional y hace que la log-verosimilitud sea cóncava, lo que asegura la existencia de un único máximo global bajo el supuesto de que la matriz de diseño tiene rango completo [4]. Los estimadores MLE son consistentes, asintóticamente eficientes (alcanzan la cota de Cramér-Rao) y normales, propiedades que habilitan la inferencia por pruebas z y la construcción de intervalos de confianza basados en la distribución normal.

Desde una perspectiva sustantiva, los coeficientes son interpretables como cambios en log-odds y sus exponenciales como *odds ratios*, la medida de efecto estándar en epidemiología y medicina deportiva [1]. Esta interpretabilidad directa resulta crucial para que los resultados sean utilizables por el cuerpo médico y técnico del equipo.

La elección del logit frente a alternativas como el probit o el cloglog (complementario log-log) se sustenta adicionalmente en los resultados de las cinco pruebas formales de especificación aplicadas en la Sección 8, que confirmarán *a posteriori* que el enlace logit es adecuado para estos datos.

3.3. Preprocesamiento

`Position` se codificó mediante *one-hot encoding* con `drop_first=True`, fijando `Defender` como categoría de referencia (primera en orden alfabético). Los coeficientes de las dummies restantes (`Forward`, `Goalkeeper`, `Midfielder`) cuantifican los efectos diferenciales respecto a los defensas, manteniendo constantes el resto de covariables. Esta elección de referencia es técnica y no implica juicio alguno sobre el nivel de riesgo inherente a la posición defensiva.

Las 14 variables continuas se estandarizaron a media 0 y desviación estándar 1 ajustando el escalador *únicamente* sobre el conjunto de entrenamiento ($n = 640$, partición estratificada 80 %/20 %, semilla aleatoria 42). El escalador ajustado sobre el entrenamiento se aplicó luego sin reajuste al conjunto de prueba ($n = 160$), evitando cualquier fuga de información del test hacia el train. La estandarización permite comparar directamente las magnitudes de los coeficientes entre variables con unidades originales incompatibles (milisegundos, puntos de escala, kilogramos, etc.), y hace que los AME sean interpretables en una escala común de desviaciones estándar.

4. ESTIMACIÓN E INFERENCIA

4.1. Método de estimación y propiedades asintóticas

Los parámetros se estimaron por máxima verosimilitud (MLE) maximizando la log-verosimilitud de la familia Bernoulli:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left[y_i \mathbf{x}_i^\top \boldsymbol{\beta} - \log(1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}) \right]. \quad (8)$$

Numéricas vs Injury_Next_Season




Figura 1: Variables numéricas estratificadas por clase (0: no lesionado, 1: lesionado). Las diferencias más marcadas se observan en Stress, Reaction_Time, Sleep, Balance, Agility y Nutrition, donde las cajas presentan poco solapamiento. Por el contrario, Age, Height, BMI, Matches y Training_Hrs muestran distribuciones casi idénticas entre grupos, anticipando su ausencia de poder predictivo en el modelo multivariado.

El algoritmo IRLS (*Iteratively Reweighted Least Squares*) convergió en 9 iteraciones con un valor de la función objetivo de 0,118176. La convergencia en menos de 10 iteraciones es indicativa de una superficie de log-verosimilitud bien comportada y descarta problemas de separación perfecta o quasi-separación global.

Bajo condiciones de regularidad estándar:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}^{-1}(\beta)), \quad (9)$$

donde $\mathbf{I}(\beta)$ es la matriz de información de Fisher evaluada en el verdadero parámetro. Esta convergencia asintótica habilita la construcción de intervalos de confianza aproximados y la realización de pruebas z para contrastes individuales. Los errores estándar se obtienen a partir de la raíz cuadrada de los elementos diagonales de $\mathbf{I}^{-1}(\hat{\beta})$, la inversa de la información de Fisher observada.

4.2. Modelo base: ajuste y significancia

El modelo base (18 variables) alcanza una log-verosimilitud de $\ell(\hat{\beta}) = -75,633$ frente a $\ell_0 = -443,614$ del modelo nulo.

Tabla 3: Comparación de modelos: AIC, BIC y AUC sobre el conjunto de prueba. El modelo final con interacción minimiza el AIC.

Modelo	Vars.	LL	AIC	BIC	AUC
Base	18	-75,63	189.27	274.03	—
Reducido	12	-76,49	178.97	236.97	0.9972
Final+int.	13	-74,07	176.14	238.60	0.9972
LASSO	13	-79,82	187.65	250.11	0.9978

El estadístico de razón de verosimilitudes $\text{LLR} = 735,96$ ($p < 10^{-144}$) es consistente con que el conjunto de 18 predictores aporta capacidad explicativa sustancial respecto al modelo nulo, aunque la magnitud del LLR debe interpretarse con cautela dado el posible optimismo post-selección. El pseudo- R^2 de McFadden de 0.8295 es elevado: en la literatura de regresión logística, valores entre 0.20 y 0.40 ya se consideran buenos, y valores superiores a 0.50 son inusuales en datos observacionales reales. Sin embargo, valores muy altos en presencia de separación fuerte entre clases reflejan la estructura del dataset más que la bondad del modelo en sentido estricto.




Figura 2: Matriz de correlaciones de Pearson. Células rojas intensas: correlación positiva fuerte; azules intensas: correlación negativa fuerte. Destacan: (i) la banda diagonal inferior de Stress y Sleep con el target ($r = 0,53$ y $r = -0,51$); (ii) el bloque rojo Peso-IMC ($r = 0,85$) que motivó la eliminación de Talla y Peso; (iii) la ausencia de correlaciones inter-predictores altas fuera de ese bloque, descartando multicolinealidad estructural en el resto del dataset.

Eleven de las 18 variables resultaron significativas al 5 % en el contexto multivariado. Las siete no significativas (Training_Hours, Age, Position_Goalkeeper, Position_Midfielder, BMI, Matches_Season, Position_Forward) coinciden exactamente con las identificadas como no asociadas en el análisis bivariado de la Sección 2.5, reforzando la coherencia entre las fases exploratoria y confirmatoria del análisis.

5. DIAGNÓSTICO DE MULTICOLINEALIDAD

El diagnóstico de multicolinealidad se realizó con dos indicadores complementarios: el número de condición κ para una perspectiva global, y el factor de inflación de la varianza (VIF) para una perspectiva variable a variable.

El número de condición se calcula a partir de los valores propios de la matriz $\mathbf{X}^\top \mathbf{X}$ de las variables predictoras estandarizadas:

$$\kappa = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} = \sqrt{\frac{1860,53}{62,46}} = 5,458 < 10. \quad (10)$$

Dado que $\kappa < 10$ (umbral de Belsley, Kuh y Welsch [13]), se descarta multicolinealidad moderada o severa a nivel global. La Tabla 4 presenta los VIF completos. Todos son inferiores a 2.1, muy por debajo del umbral convencional de preocupación de $\text{VIF} > 5$. El VIF más elevado corresponde a Warmup_Routine_Adherence (2.078), valor que refleja su correlación estructural con las dummies de posición (distintas posiciones tienen distintas culturas de calentamiento), pero




Figura 3: Coeficientes estandarizados del modelo base (18 variables), ordenados por magnitud absoluta. Las barras rojas (positivas) representan factores de riesgo y las verdes (negativas) factores protectores. El tiempo de reacción y el nivel de estrés encabezan el ranking de riesgo con coeficientes superiores a +1,3; el balance y el calentamiento lideran los factores protectores con valores inferiores a -1,4. Las variables de posición, edad, IMC y partidos agrupadas alrededor de cero anticipan su posterior eliminación por el criterio AIC.

Tabla 4: Factor de inflación de la varianza (VIF) y tolerancia. El umbral de preocupación es $VIF > 5$; aquí todos los valores están muy por debajo. La tolerancia elevada confirma alta independencia entre predictores.

Variable	VIF	Tolerancia
Warmup_Adherence	2.078	0.481
Position_Midfielder	1.454	0.688
Position_Forward	1.329	0.752
Stress_Level	1.294	0.773
Position_Goalkeeper	1.287	0.777
Balance_Score	1.256	0.796
Sleep_Hours	1.254	0.798
Sprint_Speed	1.227	0.815
Reaction_Time	1.218	0.821
Knee_Strength	1.207	0.829
Agility_Score	1.181	0.847
Previous_Injury	1.179	0.848
Hamstring_Flex	1.167	0.857
Nutrition_Quality	1.143	0.875
BMI	1.038	0.963
Training_Hrs	1.035	0.967
Age	1.026	0.975
Matches_Season	1.020	0.980

que no es problemático en términos de estabilidad de los estimadores. Los VIF de las tres dummies de posición oscilan entre 1.29 y 1.45, valores moderados y esperables por construcción del one-hot encoding.

La tolerancia (inverso del VIF) permaneció en todos los casos por encima de 0.48, indicando que cada variable aporta información mayoritariamente independiente al modelo. En consecuencia, el diagnóstico de multicolinealidad valida el conjunto de 18 predictores para la estimación del modelo base y confirma que la eliminación de Talla y Peso fue la única acción anticolinealidad necesaria en la fase de preprocesamiento.

6. SELECCIÓN DE VARIABLES

6.1. Eliminación regresiva por AIC

La selección de variables se realizó mediante un algoritmo de eliminación regresiva (*backward stepwise elimination*) [14]

Tabla 5: Historial de eliminación regresiva por AIC. En seis pasos el AIC se redujo en 10.30 puntos, equivalente a una mejora sustancial en el balance entre ajuste y parsimonia.

Paso	Variable eliminada	AIC	Vars.
0	— (modelo base)	189.27	18
1	Position_Forward	187.32	17
2	Matches_Past_Season	185.40	16
3	Position_Midfielder	183.54	15
4	BMI	181.69	14
5	Position_Goalkeeper	179.94	13
6	Age	178.97	12

guiado por el criterio de información de Akaike ($AIC = -2\ell + 2k$, donde k es el número de parámetros) [15]. En cada iteración, el algoritmo evalúa la eliminación de cada variable en el modelo vigente, calcula el AIC del modelo resultante en cada caso, y elimina la variable cuya supresión produce la mayor reducción del AIC. El proceso se detiene cuando ninguna eliminación adicional reduce el AIC.

En seis pasos el AIC se redujo de 189.27 a 178.97 ($\Delta = -10.30$), eliminando seis variables no informativas. A continuación se describe cada paso con detalle, incluyendo las variables candidatas evaluadas en cada iteración y la razón de la decisión.

Paso 1 — Eliminación de Position_Forward (AIC : 189,27 $\rightarrow$ 187,32, $\Delta = -1,95$). En el primer barrido, el algoritmo evalúa 18 posibles eliminaciones individuales. La supresión de Position_Forward produce la mayor reducción del AIC (-1,95), seguida a distancia por Age ($\Delta = -0,75$) y BMI ($\Delta = -0,62$). El coeficiente de Position_Forward en el modelo base era prácticamente nulo ($\hat{\beta} = 0,04$, $p = 0,82$), indicando que los delanteros no presentan diferencias estadísticamente distinguibles en el riesgo de lesión respecto a los defensas. Su eliminación libera un grado de libertad sin pérdida de capacidad explicativa.

Paso 2 — Eliminación de Matches_Past_Season (AIC : 187,32 $\rightarrow$ 185,40, $\Delta = -1,92$). El número de partidos jugados la temporada anterior no discrimina entre lesionados y no lesionados en el contexto multivariado ($p = 0,76$ en el modelo base, $\Delta_r = 0,91$ en la Tabla 2). Una vez que el modelo controla por la condición física actual (fuerza, balance, velocidad) y los hábitos (sueño, nutrición), el historial de carga competitiva pierde poder predictivo, posiblemente porque el estado físico presente ya incorpora el efecto acumulado de la carga pasada.

Paso 3 — Eliminación de Position_Midfielder (AIC : 185,40 $\rightarrow$ 183,54, $\Delta = -1,86$). Con Position_Forward ya eliminada, la dummy de mediocampista se convierte en la variable menos informativa. Este resultado reitera el hallazgo del análisis bivariado ($\chi^2 = 2,42$, $p = 0,49$): la posición no modula la probabilidad de lesión de forma apreciable una vez que se controla por la condición física individual.

Paso 4 — Eliminación de BMI (AIC : 183,54 $\rightarrow$ 181,69, $\Delta = -1,85$). El IMC muestra correlación casi nula con la lesión ($r = 0,02$ en el análisis bivariado) y resulta no significativo en el modelo base ($p = 0,69$). En el contexto multivariado, su información queda completamente absorbida por las variables de capacidad física que lo correlacionan: un IMC elevado en atletas no implica obesa sino mayor masa

muscular, y la fuerza de rodilla y la velocidad de sprint capturan directamente ese componente de capacidad física.

Paso 5 — Eliminación de Position_Goalkeeper (AIC : 181,69 → 179,94, $\Delta = -1,75$). La última dummy de posición restante tampoco aporta información discriminatoria. Los porteros, pese a su rol muy distinto durante el partido, no presentan un perfil de lesión estadísticamente diferente al de los defensas una vez que se controlan las variables de condición física.

Paso 6 — Eliminación de Age (AIC : 179,94 → 178,97, $\Delta = -0,97$). La edad es la variable con menor variabilidad del dataset (rango 18–24 años, DE= 1,87) y la menor correlación con el target ($r = 0,01$). En una muestra de jugadores jóvenes con rango etario estrecho, la edad pierde por completo el poder diferenciador que podría tener en estudios con mayor heterogeneidad etaria. Su eliminación produce la menor ganancia de AIC de los seis pasos, pero aún así mejora el criterio.

El orden de eliminación refleja el nivel de redundancia de cada variable en el contexto multivariado: las dummies de posición se eliminan primero porque su efecto es capturado por las covariables de condición física; los partidos jugados y el IMC, porque su información queda absorbida por las variables de estado físico actual; y la edad, por la estrechez del rango etario muestral.

Un resultado notable es la retención de *Training_Hours_Per_Week*, cuyo p -valor es de 0.10 en el modelo base. Esto ilustra una diferencia fundamental entre la selección por AIC y la selección por p -valor: el AIC considera el aporte conjunto de la variable al ajuste global del modelo, penalizando únicamente por el número de parámetros añadidos. Una variable puede tener $p > 0,05$ en el test z individual y aún así mejorar el AIC si su inclusión aporta poder predictivo suficiente para compensar la penalización de complejidad. En este caso, cada aumento de una desviación estándar en las horas de entrenamiento se asocia con un incremento de 1.35 pp en la probabilidad de lesión, efecto marginal que, aunque no significativo al 5 %, el algoritmo AIC juzga como informativo suficiente para retener la variable.

La prueba de razón de verosimilitudes (LRT) no encontró evidencia de que las seis variables eliminadas, en conjunto, mejoren el ajuste:

$$\Lambda = 2(-75,633 + 76,487) = 1,708, \quad \chi^2(6), \quad p = 0,944. \quad (11)$$

El BIC se redujo en 37.06 puntos (274,03 → 236,97), lo que favorece el modelo parsimonioso. La Tabla 6 muestra el resumen.

Advertencia metodológica sobre inferencia post-selección.

La eliminación regresiva por AIC es un procedimiento adaptativo: las variables finales fueron seleccionadas después de examinar los datos, lo que invalida parcialmente los p -valores e intervalos de confianza de los coeficientes bajo la teoría clásica. En la práctica, los p -valores post-selección tienden a ser optimistas (sesgo de selección) y los IC pueden ser más estrechos de lo que correspondería [16], [17]. La validación por LASSO y la validación cruzada de 10 folds mitigan parcialmente este sesgo al evaluar el desempeño

Tabla 6: Modelo reducido (12 variables, $n = 640$). * $p < 0,05$; ** $p < 0,01$; *** $p < 0,001$.

Variable	$\hat{\beta}$	SE	z	p
(Intercepto)	+0,814	0.376	+2,17	0,030*
Training_Hrs	+0,391	0.234	+1,67	0,095
Previous_Injury	+0,929	0.245	+3,79	< 0,001***
Knee_Strength	-0,831	0.248	-3,35	0,001**
Hamstring_Flex	-1,028	0.240	-4,28	< 0,001***
Reaction_Time	+1,346	0.257	+5,24	< 0,001***
Balance_Score	-1,467	0.303	-4,84	< 0,001***
Sprint_Speed	-1,311	0.283	-4,64	< 0,001***
Agility_Score	-0,701	0.242	-2,89	0,004**
Sleep_Hours	-1,171	0.267	-4,38	< 0,001***
Stress_Level	+1,279	0.274	+4,66	< 0,001***
Nutrition_Quality	-1,202	0.267	-4,51	< 0,001***
Warmup_Adherence	-1,401	0.479	-2,93	0,003**
LL	-76,487			
Pseudo- R^2 McF.	0,8276			
AIC / BIC	178,97 / 236,97			

fuera de muestra, pero no lo eliminan completamente. Las conclusiones sustantivas sobre dirección y magnitud de efectos son robustas, pero los valores exactos de p e IC deben interpretarse con cautela.

6.2. LASSO como especificación alternativa

Para verificar la robustez de la selección por AIC, se ajustó un modelo de regresión logística regularizado mediante LASSO [18] (penalización L1). El hiperparámetro de regularización $\lambda^* = 2,560$ se seleccionó mediante validación cruzada de 10 particiones evaluando 50 valores candidatos sobre la log-pérdida negativa. LASSO conservó 13 variables, descartando exactamente las mismas cinco que el backward: BMI, Matches_Past_Season, Position_Forward, Position_Goalkeeper y Position_Midfielder. La única diferencia es la retención de Age ($\hat{\beta} = 0,052$) con un coeficiente residual pequeño, que el backward había eliminado en el paso 6 por mejorar el AIC en apenas 0.97 puntos.

Los coeficientes LASSO presentan magnitudes entre el 75 y el 80 % de los del backward, comportamiento esperable dado que la regularización L1 introduce un sesgo controlado a cambio de reducir la varianza de los estimadores (*shrinkage*). Los signos de los coeficientes son idénticos en los dos modelos para todas las variables comunes, lo que es consistente con que la dirección de los efectos asociados es robusta a la elección del método de estimación.

La convergencia de ambos métodos —uno basado en criterios de información y otro en regularización— sobre el mismo conjunto sustantivo de variables aporta evidencia consistente de que la selección no es un artefacto del método. No obstante, ambos procedimientos se aplican sobre los mismos datos de entrenamiento, por lo que el sesgo post-selección es inherente y los p -valores del modelo final deben interpretarse con la cautela discutida en la Sección 6.




Figura 4: Comparación de coeficientes: Backward (azul) vs. LASSO (naranja), ordenados de mayor a menor magnitud LASSO. La concordancia en signos es perfecta para todas las variables. Los coeficientes LASSO son sistemáticamente más pequeños en magnitud (*shrinkage*), efecto esperado de la penalización L1. Las variables con coeficiente cero en LASSO (Position, BMI, Matches, Age) son exactamente las descartadas por backward, validando la consistencia de ambas metodologías de selección.

Tabla 7: Resultados de las tres interacciones evaluadas. Solo Stress×Sleep mejora el AIC y resulta estadísticamente significativa tanto por test z como por LRT.

Interacción	$\hat{\beta}$	p	AIC	Δ AIC
Stress×Sleep	-0,803	0,029	176,14	-2,84
PrevInj×KneeStr	-0,195	0,463	180.43	+1,46
Warmup×ReactTime	-0,020	0,968	180.97	+2,00

7. TÉRMINOS DE INTERACCIÓN

Se evaluaron tres términos de interacción, cada uno con motivación teórica explícita. Cada interacción se incorporó por separado al modelo reducido como producto cruzado de las variables estandarizadas y se comparó mediante prueba LRT y criterio AIC contra el modelo aditivo de 12 predictores. La Tabla 7 sintetiza los resultados.

La interacción **Stress×Sleep** es significativa ($p = 0,029$, $LR = 4,835$, $p_{LRT} = 0,028$) y reduce el AIC en 2.84 puntos, superando el umbral convencional de 2 puntos propuesto por Burnham y Anderson [19] como evidencia sustancial. El signo negativo ($\hat{\beta} = -0,803$) indica que el efecto del estrés sobre el riesgo de lesión es *atenuado* cuando el jugador duerme más: el término de interacción resta de los log-odds a medida que el producto Stress×Sleep aumenta. El BIC presenta un leve empeoramiento de 1.63 puntos respecto al modelo aditivo, comportamiento esperable dada la mayor penalización por parámetro del BIC ($\log n = 6,46$ vs. 2 del AIC). La significancia formal del LRT y la relevancia clínica del hallazgo justifican la inclusión del término a pesar de la leve penalización del BIC.

La interacción **PrevInj×KneeStr** ($p = 0,463$, Δ AIC = +1,46) no resulta significativa. Aunque la hipótesis de que la fuerza de rodilla compensa el riesgo acumulado por lesiones previas es teóricamente plausible, los datos no ofrecen evidencia de este efecto modulador en la escala bivariada especificada. La interacción **Warmup×ReactTime** ($p = 0,968$,

Tabla 8: Modelo final (12 predictores + interacción, $n = 640$). * $p < 0,05$; ** $p < 0,01$; *** $p < 0,001$.

Variable	$\hat{\beta}$	SE	z	p
(Intercepto)	+0,918	0.388	+2,36	0,018*
Training_Hrs	+0,456	0.238	+1,92	0,055
Previous_Injury	+0,993	0.253	+3,92	< 0,001***
Knee_Strength	-0,920	0.260	-3,53	< 0,001***
Hamstring_Flex	-1,153	0.256	-4,51	< 0,001***
Reaction_Time	+1,370	0.258	+5,31	< 0,001***
Balance_Score	-1,427	0.295	-4,85	< 0,001***
Sprint_Speed	-1,341	0.286	-4,70	< 0,001***
Agility_Score	-0,713	0.249	-2,87	0,004**
Sleep_Hours	-1,150	0.268	-4,29	< 0,001***
Stress_Level	+1,372	0.287	+4,77	< 0,001***
Nutrition_Quality	-1,205	0.267	-4,52	< 0,001***
Warmup_Adherence	-1,541	0.493	-3,12	0,002**
Stress×Sleep	-0,803	0.369	-2,18	0,029*
LL	-74,069			
Pseudo- R^2 McF.	0,8330			
Pseudo- R^2 Nagelkerke	0,9132			
AIC / BIC	176,14 / 238,60			

Δ AIC = +2,00) tampoco muestra relevancia estadística: la hipótesis de que el calentamiento es más beneficioso para jugadores lentos de reacción no encuentra soporte empírico. Estas dos interacciones se descartan y el modelo final conserva únicamente la interacción significativa.

La Tabla 8 presenta el modelo final completo con los 13 predictores y el término de interacción.

La Figura 5 visualiza el efecto modulador mediante curvas de probabilidad predicha en función del nivel de estrés para tres niveles de sueño: bajo (-1,5 DE), promedio y alto (+1,5 DE), manteniendo el resto de covariables en sus medias muestrales. El patrón es revelador: con sueño deficiente, la probabilidad de lesión sube desde valores bajos hasta prácticamente el 100 % a medida que el estrés aumenta hacia sus niveles máximos; con sueño adecuado, la curva se aplana considerablemente, indicando que el impacto del estrés queda amortiguado de forma sustancial.

8. DIAGNÓSTICO DEL MODELO

El diagnóstico del modelo reducido se estructura en tres sub-fases: (A) pruebas formales de especificación, (B) análisis de residuos y sobredispersión, y (C) análisis de observaciones influyentes y sensibilidad.

8.1. Sub-Fase A: Pruebas formales de especificación

La Tabla 9 resume los cinco resultados. Ninguno de los p -valores es inferior a 0.15, lo que implica que no hay evidencia para rechazar ninguno de los supuestos evaluados.




Figura 5: Efecto modulador del sueño sobre el estrés. Cada curva corresponde a un nivel de sueño fijado ($-1,5$ DE, promedio, $+1,5$ DE) mientras el resto de covariables se mantiene en sus medias muestrales. Con sueño deficiente la probabilidad de lesión escala hacia 100 % al aumentar el estrés; con sueño adecuado la curva se aplana drásticamente. Un jugador con estrés alto ($+1,5$ DE) tiene una probabilidad de lesión 40 % mayor si duerme poco que si duerme adecuadamente.

Tabla 9: Pruebas formales de especificación del modelo reducido. Todos los supuestos son confirmados a cualquier nivel de significancia razonable.

Prueba	Estadístico	p	Resultado
Box-Tidwell	$p_{\min} = 0,154$	—	Linealidad OK
Pregibon	$\hat{\alpha} = -0,026$	0.376	Enlace OK
Stukel	Wald = 2,479	0.290	Sin asimetrías
RESET	Wald = 2,381	0.304	Forma func. OK
Hosmer-L.	HL = 4,401	0.819	Sin evidencia falta ajuste

Tabla 10: Test de Box-Tidwell: coeficiente del término $X_j \cdot \log X_j$ y p -valor por variable continua. El p -valor mínimo (0.154) corresponde a Sleep_Hours, la variable más próxima a un posible efecto no lineal, pero sin superar el umbral de 5 %.

Variable	$\hat{\beta}_{BT}$	p
Sleep_Hours	+8,948	0.154
Previous_Injury	-0,436	0.179
Nutrition_Quality	+0,514	0.197
Knee_Strength	-0,599	0.345
Agility_Score	+0,303	0.402
Reaction_Time	+0,103	0.515
Training_Hrs	-0,221	0.663
Balance_Score	+0,387	0.684
Hamstring_Flex	+0,154	0.776
Stress_Level	-0,024	0.907
Sprint_Speed	+2,410	0.924

8.1.1. Test de Box-Tidwell: linealidad del logit

Para cada predictor continuo X_j se incorporó al modelo un término de interacción de la forma $X_j \cdot \log(X_j)$ y se evaluó la significancia de su coeficiente mediante el test z [20]. Si este coeficiente es significativo, la relación entre X_j y el logit no es lineal, y se requiere una transformación. La Tabla 10 detalla los resultados.

Ninguno de los once predictores rechaza la linealidad del logit al 5 %, resultado que es coherente con la evidencia visual de los CR-plots (Figura 6). El caso de Sleep_Hours

merece mención especial: aunque su p -valor de 0.154 es el más cercano al umbral de significancia, y su coeficiente Box-Tidwell de +8,948 es elevado en términos absolutos, la prueba no rechaza la linealidad. La magnitud del coeficiente BT en escala estandarizada se ve amplificada por el rango estrecho de variación de las horas de sueño (5–9.5 horas), que comprime el soporte de la transformación logarítmica. El resultado neto es que no se requieren transformaciones para ninguna variable.

La Figura 6 complementa el test de Box-Tidwell con un diagnóstico visual directo mediante gráficos de componente más residuo (*component-plus-residual plots*, CR-plots) para los 11 predictores continuos del modelo reducido.

8.1.2. Pregibon link test: adecuación del enlace

Se incorporó al modelo el cuadrado del predictor lineal estimado ($\hat{\eta}^2$) como variable adicional [21]. Si el enlace logit fuera incorrecto, $\hat{\eta}^2$ recogería la curvatura no capturada y su coeficiente sería significativo. El coeficiente obtenido fue $\hat{\alpha} = -0,0258$ con $p = 0,3759$, confirmando que el enlace logit está correctamente especificado.

8.1.3. Stukel test: simetría de las colas

El test de Stukel evalúa si el enlace logit captura adecuadamente las colas superior e inferior de la distribución de probabilidades. Se descompuso el predictor lineal en sus componentes positiva ($g_+ = \hat{\eta}^2$ cuando $\hat{\eta} \geq 0$) y negativa ($g_- = \hat{\eta}^2$ cuando $\hat{\eta} < 0$) y se incorporaron al modelo. La prueba conjunta de Wald [22] sobre $H_0 : \alpha_+ = \alpha_- = 0$ arrojó $W = 2,4787$ y $p = 0,2896$, descartando asimetrías significativas en las colas.

8.1.4. RESET test: formas funcionales faltantes

El test RESET de Ramsey [23] evalúa si faltan términos polinomiales en la especificación. Se incorporaron $\hat{\eta}^2$ y $\hat{\eta}^3$ al modelo y se realizó la prueba conjunta de Wald sobre su nulidad simultánea: $W = 2,3807$, $p = 0,3041$. El modelo no requiere términos cuadráticos, cúbicos ni otras formas funcionales no lineales en el predictor.

8.1.5. Hosmer-Lemeshow test: bondad de ajuste global

Se agruparon las observaciones del conjunto de entrenamiento en diez deciles según las probabilidades predichas y se compararon, en cada grupo, las frecuencias de lesión observadas y esperadas mediante el estadístico $HL = \sum_{g=1}^{10} \left(\frac{(O_g^1 - E_g^1)^2}{E_g^1} + \frac{(O_g^0 - E_g^0)^2}{E_g^0} \right)$. El resultado fue $HL = 4,401$ con 8 grados de libertad y $p = 0,8192$, confirmando que no existen diferencias sistemáticas entre las frecuencias observadas y las predichas por el modelo en ningún segmento de la distribución de probabilidades.

Conclusión integrada de la Sub-Fase A. Los cinco tests abordan distintas amenazas potenciales a la validez del modelo logístico: Box-Tidwell verifica la linealidad de la relación $X_j \rightarrow \eta$, Pregibon y Stukel examinan la adecuación de la función de enlace, RESET detecta formas funcionales no lineales omitidas en el predictor lineal, y Hosmer-Lemeshow evalúa la bondad de ajuste en toda la distribución de probabilidades. El hecho de que los cinco tests pasen simultáneamente, todos con $p > 0,15$, es evidencia convergente

Component-Residual plots — diagnóstico visual de linealidad del logit




Figura 6: Gráficos de componente más residuo (CR-plots) para los 11 predictores continuos del modelo reducido. Cada panel superpone la relación teórica lineal (línea negra discontinua) con la curva Lowess ajustada sobre los residuos (línea roja continua). La coincidencia prácticamente exacta entre ambas curvas en todos los paneles aporta evidencia visual consistente con la adecuación de la especificación lineal del logit para cada predictor. La dispersión heterogénea visible en los extremos de algunas variables (especialmente `Previous_Injury_Count` y `Stress_Level_Score`) es esperable dado el tamaño muestral de $n = 640$ en entrenamiento, y no constituye evidencia de no-linealidad sino de varianza empírica mayor en los cuantiles extremos de la distribución del predictor.

Tabla 11: Estadísticos de residuos (conjunto de entrenamiento, $n = 640$). Las proporciones de outliers son muy inferiores al 5 % teóricamente esperado bajo buen ajuste.

Tipo	Media	DE	Mín	Máy	Outliers
Pearson	-0,015	0.629	-7,07	3,41	13 (2.0 %)
Devianza	+0,002	0.489	-2,80	2,25	7 (1.1 %)
Anscombe	+0,005	0.805	-2,88	2,26	9 (1.4 %)

y robusta de que el modelo logístico con especificación lineal es una aproximación adecuada para estos datos. No se encontró evidencia que requiera transformaciones de variables, términos polinomiales, cambio de enlace ni modificaciones estructurales. Esto es consistente con que los 13 coeficientes estimados sean interpretaciones plausibles de las asociaciones subyacentes; los OR y AME reportados en la Sección 9 pueden leerse con confianza metodológica razonable, sujeto a las limitaciones observacionales del diseño y al sesgo post-selección discutido.

8.2. Sub-Fase B: Análisis de residuos y sobredispersión

Se calcularon tres tipos de residuos complementarios. Los residuos de **Pearson** ($r_i = (y_i - \hat{\mu}_i) / \sqrt{\hat{\mu}_i(1 - \hat{\mu}_i)}$)

son los más sensibles a observaciones individuales influyentes. Los residuos de **deviance** ($d_i = \text{signo}(y_i - \hat{\mu}_i) \sqrt{-2[y_i \log \hat{\mu}_i + (1 - y_i) \log(1 - \hat{\mu}_i)]}$) reflejan la contribución de cada observación a la log-verosimilitud. Los residuos de **Anscombe** ofrecen una aproximación más cercana a la distribución normal. Las medias de los tres tipos se ubican prácticamente en cero, confirmando ausencia de sesgo sistemático. Las proporciones de outliers (2.0 %, 1.1 % y 1.4 %) están todas por debajo del 5 % esperado bajo buen ajuste del modelo.

La Figura 7 muestra los tres tipos de residuos contra el predictor lineal $\hat{\eta}$. El patrón observado es el esperado en regresión logística binaria: dos bandas de puntos, una para $Y = 1$ (residuos positivos) y otra para $Y = 0$ (residuos negativos), con la masa de puntos bien concentrada dentro de las bandas de ± 2 . La nube es simétrica y no presenta tendencias sistemáticas, curvatura ni patrones de embudo.

El **Q-Q plot** (Figura 8) de los residuos de deviance muestra una ligera curvatura en forma de S en las colas, esperable por la naturaleza discreta de la respuesta, y no constituye una violación de los supuestos.

El **half-normal plot** con envelope simulado (Figura 9, 100 réplicas) confirma que el 0 % de los residuos cae fuera de la

banda al 95 %, validando explícitamente que el modelo es compatible con sus propias predicciones.

8.2.1. Sobredispersión

En modelos GLM con familia binomial, la sobredispersión ocurre cuando la varianza empírica supera la teórica $\mu(1 - \mu)$. El ratio $\chi^2_{\text{Pearson}}/gl = 0,404 \ll 1,5$ está notablemente por debajo de 1, descartando sobredispersión: los errores estándar son confiables sin corrección *sandwich* ni ajuste mediante modelo quasi-binomial. Un ratio inferior a 1 indica incluso leve *infra*-dispersión, consistente con un modelo que predice probabilidades bien calibradas, cercanas a 0 y 1.

8.3. Sub-Fase C: Observaciones influyentes y sensibilidad

Procedimiento de cálculo. Para cada observación i del conjunto de entrenamiento ($n = 640$) se calcularon tres métricas de diagnóstico individual, cada una con su respectivo umbral de referencia.

La **distancia de Cook** D_i cuantifica el cambio global en el vector de coeficientes estimados si se eliminara la observación i :

$$D_i = \frac{(\hat{\beta} - \hat{\beta}_{(i)})^\top \mathbf{I}(\hat{\beta})(\hat{\beta} - \hat{\beta}_{(i)})}{k}, \quad (12)$$

donde $\hat{\beta}_{(i)}$ es el vector de coeficientes re-estimado sin la observación i , $\mathbf{I}(\hat{\beta})$ es la matriz de información de Fisher observada, y $k = 13$ es el número de parámetros. El umbral convencional es $D_i > 4/n = 0,00625$; un valor de $D_i > 0,5$ indicaría un punto altamente influyente.

El **leverage** h_{ii} mide cuánto se aleja la observación i del centro del espacio de covariables:

$$h_{ii} = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{x}_i \hat{\mu}_i (1 - \hat{\mu}_i), \quad (13)$$

donde $\mathbf{W} = \text{diag}(\hat{\mu}_i(1 - \hat{\mu}_i))$ es la matriz de pesos del algoritmo IRLS. El umbral $h_{ii} > 2k/n = 0,0406$ identifica puntos de palanca elevados.

Los **residuos studentizados** r_i^* estandarizan los residuos de Pearson por su desviación estándar teórica: $r_i^* = r_i^P / \sqrt{1 - h_{ii}}$. Un valor $|r_i^*| > 2$ señala outliers en el espacio de respuesta. Se clasifica como *caso crítico* toda observación que supere simultáneamente los tres umbrales.

La Figura 10 muestra los tres diagramas de influencia. Los picos de la distancia de Cook se ubican alrededor de 0.06, muy por debajo del umbral grave de 0.5. El diagrama de leverage muestra 110 observaciones por encima del umbral $2k/n = 0,041$, valor elevado que refleja la presencia de casos con perfiles de covariables inusuales, sin que ningún caso sea un outlier aislado extremo. La dispersión de residuos studentizados es cómoda, con solo 15 valores superiores a 2 en valor absoluto.

El análisis de sensibilidad revela el patrón esperado: al eliminar los 10 puntos críticos, todos los coeficientes se vuelven más extremos en magnitud (protectores más negativos, factores de riesgo más positivos), lo que sugiere que estos casos intermedios suavizan las relaciones estimadas. En ningún caso el signo de los coeficientes cambia, lo que es consistente con robustez direccional de las asociaciones.

Se decide conservar el modelo original con todas las observaciones por tres razones: (1) la robustez direccional es

Tabla 12: Conteo de observaciones influyentes y análisis de sensibilidad al excluir los 10 casos críticos. Todos los signos se preservan (robustez direccional completa).

Variable	Original	Sin crít.	Cambio
<i>Conteos de influencia</i>			
Cook $D_i > 4/n$		45 observaciones	
Leverage $h_{ii} > 2k/n$		110 observaciones	
$ r_i > 2$ (stud.)		15 observaciones	
3 alarmas (crít.)		10 observaciones	
<i>Sensibilidad de coeficientes</i>			
Training_Hrs	+0,391	+0,376	-3,8 %
Previous_Inj	+0,929	+1,160	+24,9 %
Knee_Strength	-0,831	-1,140	+37,2 %
Hamstring_Flex	-1,028	-1,376	+33,9 %
Reaction_Time	+1,346	+1,540	+14,4 %
Balance_Score	-1,467	-1,551	+5,7 %
Sprint_Speed	-1,311	-1,670	+27,4 %
Agility	-0,701	-0,945	+35,0 %
Sleep_Hours	-1,171	-1,741	+48,7 %
Stress_Level	+1,279	+1,421	+11,1 %
Nutrition	-1,202	-1,388	+15,6 %
Warmup	-1,401	-1,393	-0,6 %

la propiedad inferencial más importante en epidemiología deportiva; (2) eliminar los 10 casos implicaría descartar situaciones clínicamente reales; y (3) el modelo conservador ofrece estimaciones más generalizables.

9. RESULTADOS Y DISCUSIÓN

9.1. Odds Ratios, IC 95 % y efectos marginales promedio

La Tabla 13 consolida los resultados del modelo final. El *odds ratio* (OR) cuantifica el cambio multiplicativo en las odds de lesión asociado a un incremento de una desviación estándar en el predictor: $OR_j = e^{\hat{\beta}_j}$. Los intervalos de confianza al 95 % se construyen exponenciando el IC de Wald del coeficiente: $OR_j \in [e^{\hat{\beta}_j - 1,96 SE_j}, e^{\hat{\beta}_j + 1,96 SE_j}]$.

El efecto marginal promedio (AME) cuantifica el cambio absoluto medio en la probabilidad de lesión ante una variación de una unidad en el predictor j , evaluado en todos los jugadores de la muestra con sus valores observados de covariables:

$$AME_j = \frac{1}{n} \sum_{i=1}^n \hat{\mu}_i (1 - \hat{\mu}_i) \hat{\beta}_j. \quad (14)$$

Esta definición promedia sobre la heterogeneidad de las probabilidades individuales, produciendo un efecto marginal promedio que refleja el impacto en la población de estudio, no en un jugador hipotético con covariables en sus medias. Los IC al 95 % de los AME se obtienen mediante el método delta aplicado a la función no lineal $\hat{\mu}_i(1 - \hat{\mu}_i)\hat{\beta}_j$.

9.2. Interpretación del forest plot y del gráfico de AME

La Figura 11 presenta el *forest plot* de OR en escala logarítmica. La elección de escala logarítmica es crucial: en esta escala los OR son simétricos respecto al valor nulo ($OR = 1$), lo que facilita la comparación visual entre factores de riesgo ($OR > 1$) y factores protectores ($OR < 1$). Todos los intervalos de confianza, salvo el de Training_Hrs, excluyen la línea de




Figura 7: Residuos de Pearson (izquierda), devianza (centro) y Anscombe (derecha) frente al predictor lineal $\hat{\eta}$. Las dos bandas de puntos son estructurales del modelo binario (banda superior: $Y = 1$; inferior: $Y = 0$). La distribución simétrica y la ausencia de tendencias sistemáticas son consistentes con una especificación adecuada del modelo.

Tabla 13: Resultados del modelo final: coeficientes, OR e IC 95 %, AME y p -valores. * $p < 0,05$; ** $p < 0,01$; *** $p < 0,001$. Los OR de Training_Hrs no son significativos (IC incluye 1.0).

Variable	$\hat{\beta}$	SE	OR [IC 95 %]	AME (pp)	IC 95 % AME	p
<i>Factores de riesgo</i>						
Reaction_Time	+1,346	0.257	3,84 [2,32, 6,35]	+4,65	[+3,12, +6,18]	< 0,001***
Stress_Level	+1,279	0.274	3,59 [2,10, 6,15]	+4,42	[+2,75, +6,09]	< 0,001***
Previous_Injury	+0,929	0.245	2,53 [1,57, 4,10]	+3,21	[+1,67, +4,76]	< 0,001***
Training_Hrs	+0,391	0.234	1,48 [0,93, 2,34]	+1,35	[-0,21, +2,91]	0,095
<i>Factores protectores</i>						
Agility_Score	-0,701	0.242	0,50 [0,31, 0,80]	-2,42	[-4,02, -0,82]	0,004**
Knee_Strength	-0,831	0.248	0,44 [0,27, 0,71]	-2,87	[-4,45, -1,29]	0,001**
Hamstring_Flex	-1,028	0.240	0,36 [0,22, 0,57]	-3,55	[-5,02, -2,09]	< 0,001***
Sleep_Hours	-1,171	0.267	0,31 [0,18, 0,52]	-4,05	[-5,65, -2,44]	< 0,001***
Nutrition_Quality	-1,202	0.267	0,30 [0,18, 0,51]	-4,15	[-5,82, -2,49]	< 0,001***
Sprint_Speed	-1,311	0.283	0,27 [0,16, 0,47]	-4,53	[-6,25, -2,81]	< 0,001***
Warmup_Adherence	-1,401	0.479	0,25 [0,10, 0,63]	-4,84	[-7,93, -1,75]	0,003**
Balance_Score	-1,467	0.303	0,23 [0,13, 0,42]	-5,07	[-6,96, -3,19]	< 0,001***
<i>Interacción</i>						
Stress×Sleep	-0,803	0.369	0,45 [0,22, 0,92]	—	—	0,029*

referencia (OR= 1), confirmando la significancia estadística de cada predictor.

El rango de OR es notable: desde 0.23 (Balance, factor protector más fuerte) hasta 3.84 (Reaction_Time, factor de riesgo más fuerte). Esto implica que un jugador con balance corporal una desviación estándar por encima del promedio tiene odds de lesión que son el 23 % de las de un jugador promedio —es decir, una reducción del 77 % en las odds—, mientras que un jugador con tiempo de reacción una desviación estándar más lento que el promedio tiene odds 3.84 veces mayores.

La Figura 12 muestra los AME en puntos porcentuales. A diferencia de los OR, los AME son directamente comparables entre factores de riesgo y protectores, y tienen interpretación directa: el balance corporal reduce en promedio 5.07 pp la probabilidad de lesión por cada desviación estándar adicional; el tiempo de reacción lento la aumenta en 4.65 pp.

El rango total de AME va desde -5,07 pp (Balance) hasta +4,65 pp (Reaction_Time), un rango de casi 10 puntos porcentuales sustancial considerando que la probabilidad media de lesión es del 50 %.

9.3. Interpretación por dimensiones

9.3.1. Dimensión neuromuscular

El tiempo de reacción es el factor de riesgo más fuerte del modelo (OR = 3,84, AME= +4,65 pp, $p < 0,001$). Este resultado es consistente con la literatura [8], que sugiere que tiempos de reacción más lentos podrían asociarse con menor capacidad de ajuste postural reactivo ante situaciones inesperadas. En este estudio la asociación es observacional y no implica causalidad directa. La diferencia de 21.21 ms en el tiempo de reacción promedio entre lesionados y no lesionados (Tabla 2) representa una diferencia clínicamente




Figura 8: Q-Q plot de residuos de devianza versus cuantiles teóricos normales. La ligera curvatura en forma de S en las colas es estructural de la regresión logística con respuesta discreta y no representa una violación de supuestos.

relevante, equivalente aproximadamente a una sexta parte del tiempo de respuesta estándar.

El balance corporal es el factor protector de mayor magnitud ($OR=0,23$, $AME=-5,07$ pp, $p < 0,001$). Un mayor balance corporal se asocia con una reducción estimada del 77 % en las odds de lesión, lo que es consistente con la hipótesis de que el sistema propioceptivo contribuye a la prevención. Esta es una asociación observacional condicional en las demás covariables del modelo. La velocidad de sprint ($OR=0,27$), la nutrición ($OR=0,30$) y el sueño ($OR=0,31$) completan el grupo de protectores con odds ratios por debajo de 0.35.

9.3.2. Dimensión psicológica

El estrés crónico es el segundo factor de riesgo más poderoso ($OR=3,59$, $AME=+4,42$ pp), coherente con el modelo de Anderson y Williams [5] sobre deterioro del control motor bajo estrés. La sobrecarga psicológica activa el eje hipotálamico-hipofisario-adrenal, eleva el cortisol crónicamente, deteriora la calidad del sueño (lo que cierra un ciclo retroalimentado con la interacción Stress×Sleep), y reduce la atención sostenida durante el juego, aumentando la probabilidad de errores tácticos y posturales que desencadenan lesiones [9]. La diferencia de 12.10 puntos en el nivel de estrés entre grupos corresponde al 23 % del rango intercuartílico de esta variable, una separación clínicamente significativa.

9.3.3. Dimensión clínica e historial

El historial de lesiones previas es el tercer factor de riesgo ($OR=2,53$, $AME=+3,21$ pp), uno de los predictores más consistentes en la literatura de epidemiología deportiva [2]. La literatura [2] propone que las lesiones pasadas podrían generar alteraciones biomecánicas y propioceptivas que aumentan el riesgo de recurrencia. Los datos de este estudio son consistentes con esa hipótesis, aunque el mecanismo no puede establecerse observacionalmente. El hecho de que cada lesión adicional en el historial incrementa las odds en un factor de 2.53 —manteniendo constantes la condición física actual, el sueño y los hábitos— subraya que el riesgo de recurrencia es autónomo y no mediado completamente por el deterioro físico observable.

Tabla 14: Métricas de clasificación ($n = 160$) bajo dos umbrales de decisión. El umbral óptimo (0.48) se obtiene por convergencia de cuatro criterios.

Métrica	Thr= 0,50	Thr= 0,48 (Youden)
Accuracy	0.9750	0.9813
Precision	0.9872	0.9873
Recall	0.9625	0.9750
Specificity	0.9875	0.9875
F1-Score	0.9747	0.9811
MCC	—	0.9626
AUC	0.9972	
Avg. Prec.	0.9973	
Brier Score	0.0242	

9.3.4. Dimensión de hábitos modificables

La adherencia al calentamiento ofrece el mayor retorno marginal de entre todos los factores modificables de bajo costo clínico ($OR = 0,25$, $AME= -4,84$ pp, $p = 0,003$). La reducción del 75 % en las odds de lesión entre quienes calientan versus quienes no lo hacen, con un costo de implementación prácticamente nulo, posiciona a esta intervención como la de mayor rentabilidad clínica dentro del conjunto de factores del modelo. Este resultado tiene implicaciones directas para la política deportiva: garantizar la adherencia sistemática al calentamiento en toda la plantilla debería ser la primera medida preventiva en cualquier protocolo, antes que inversiones más costosas en tecnología de monitoreo.

9.4. Evaluación de hipótesis

- (1) **Rechazada:** $\hat{\beta}_{\text{Stress}} = +1,28 > 0$, $p < 0,001$. El estrés se asocia positivamente con la lesión en la dirección predicha.
- (2) **Rechazada:** $\hat{\beta}_{\text{Sleep}} = -1,17 < 0$, $p < 0,001$. Más horas de sueño reducen significativamente el riesgo.
- (3) **Rechazada:** $\hat{\beta}_{\text{PrevInj}} = +0,93 > 0$, $p < 0,001$. El historial de lesiones predice fuertemente la lesión futura.
- (4) **Rechazada:** $\hat{\beta}_{\text{Balance}} = -1,47 < 0$, $p < 0,001$. El balance es el protector de mayor magnitud en el modelo.
- (5) **Rechazada:** $\hat{\beta}_{\text{Warmup}} = -1,40 < 0$, $p = 0,003$. El calentamiento sistemático reduce sustancialmente el riesgo.

Todas las hipótesis reciben respaldo empírico inequívoco en la dirección teóricamente predicha, con p -valores muy por debajo del 5 %. La coincidencia completa entre las direcciones predichas por la literatura y las estimadas empíricamente es consistente con la validez de construcción del modelo.

10. VALIDACIÓN PREDICTIVA

10.1. Desempeño en el conjunto de prueba

Las probabilidades predichas sobre el conjunto de prueba presentan una distribución bimodal extrema: el primer cuartil es 0.005 y el tercer cuartil es 0.996. Esto indica que el modelo asigna probabilidades cercanas a los extremos (próximas a 0 o a 1) para la gran mayoría de los jugadores, sin acumulación de masa en la zona de ambigüedad (0.3–0.7). Esta distribución bimodal es consecuencia del patrón de los datos: las diferencias entre lesionados y no lesionados son lo suficientemente pronunciadas como para que el modelo las separe con alta confianza en casi todos los casos. Solo




Figura 9: Half-normal plot con *envelope* simulado al 95 % (100 réplicas bajo el modelo ajustado). El 0 % de los residuos cae fuera de la banda simulada, validando explícitamente la compatibilidad del modelo con sus propias predicciones.




Figura 10: De izquierda a derecha: distancia de Cook con umbral $4/n = 0,006$ (línea roja), leverage con umbral $2k/n = 0,041$ y diagrama leverage vs. residuos studentizados. Los picos de Cook se ubican alrededor de 0,06, muy por debajo del umbral de 0.5. Las 110 observaciones con leverage alto reflejan perfiles de covariables inusuales, no outliers extremos aislados.

los 10 casos críticos identificados en el análisis de influencia corresponden a la zona de incertidumbre.

La **curva ROC** (Figura 14) se ubica prácticamente en la esquina superior izquierda del espacio, con $AUC = 0,9972$. Esta métrica indica que dado un par aleatorio compuesto por un jugador lesionado y uno no lesionado, el modelo asigna correctamente mayor probabilidad al lesionado en el

99.72 % de los casos [24], [25]. La diferencia entre el AUC de entrenamiento (0.9914) y el de prueba (0.9972) es de apenas 0.0058, descartando cualquier indicio de sobreajuste.

La **curva Precision-Recall** (Figura 15) complementa la ROC mostrando el balance entre precisión y recall a lo largo de todos los umbrales. La curva se mantiene con precisión cercana a 1.0 para prácticamente todo el rango de recall




Figura 11: Forest plot de OR con IC 95 % en escala logarítmica. Las barras horizontales son los intervalos de confianza; los puntos, la estimación puntual. Todos los IC salvo el de Training_Hrs excluyen la línea nula OR= 1. El rango de OR va desde 0.23 (Balance) hasta 3.84 (Reaction_Time), reflejando la amplia heterogeneidad en la magnitud de los efectos entre predictores. El IC de Warmup_Adherence es el más ancho, reflejo de la menor precisión asociada a una variable binaria.

(0–0.95), con un Average Precision de 0.9973.

10.2. Bootstrap del AUC

Procedimiento. Para cuantificar la incertidumbre muestral asociada al AUC puntual de 0.9972 sin recurrir a supuestos paramétricos, se aplicó bootstrap no paramétrico [26] sobre el conjunto de prueba ($n = 160$). En cada una de las 1000 iteraciones se extraía una remuestra de 160 observaciones con reposición del conjunto de prueba original, manteniendo las probabilidades predichas fijas (el modelo no se re-entrena). Se calculó el AUC de esa remuestra mediante el estadístico trapezoidal. Se descartaron las remuestras que producían sólo una clase (evento nulo, infrecuente por el balance 50 %/50 %). El intervalo de confianza al 95 % se obtuvo como percentiles empíricos 2.5 y 97.5 de la distribución bootstrap, lo que produce un IC robusto sin suponer normalidad del estadístico.

El análisis bootstrap entrega: media= 0,9972, DE= 0,0021, IC 95 % = [0,993, 1,000]. La media bootstrap coincide con el AUC puntual, lo que sugiere sesgo muestral pequeño en el estimador sobre este conjunto de prueba. La desviación estándar de 0.0021 evidencia alta estabilidad.

Tabla 15: Umbral óptimo según cuatro criterios. La convergencia unificada en $\tau^* = 0,48$ evidencia estabilidad del modelo.

Criterio	Thr. óptimo	Valor máx.
Youden’s J	0.48	$J = 0,9625$
F1-Score	0.48	$F1 = 0,9811$
MCC	0.48	0,9626
Cohen Kappa	0.48	0,9625

10.3. Optimización del umbral

El umbral de decisión óptimo identificado es $\tau^* = 0,48$ bajo los cuatro criterios. Con este umbral, los falsos negativos se reducen de 3 a 2 sin aumentar los falsos positivos. La cercanía entre $\tau^* = 0,48$ y el umbral por defecto (0.50) es coherente con el balance perfecto de la variable objetivo. En contextos clínicos donde el costo de un falso negativo sea mayor que el de un falso positivo, un umbral aún más bajo (0.40–0.45) sería justificable.

10.4. Calibración y Brier Score

El Brier Score [27] de 0.024 es aproximadamente 10 veces mejor que el de un modelo aleatorio (0.25 bajo target balanceado). Esta métrica confirma que las probabilidades predichas no solo discriminan entre clases (propiedad capturada por el




Figura 12: Efectos marginales promedio (AME) en puntos porcentuales con IC 95 %. Barras rojas (positivas): factores de riesgo; barras verdes (negativas): factores protectores. El balance corporal es el predictor con mayor impacto absoluto (−5,07 pp), seguido por el tiempo de reacción (+4,65 pp), el calentamiento (−4,84 pp) y la velocidad de sprint (−4,53 pp).




Figura 13: Matriz de confusión (thr= 0,50). El modelo clasifica correctamente 156 de 160 jugadores. Los 4 errores se distribuyen en 3 falsos negativos y 1 falso positivo. La relación FN/FP de 3:1 puede ajustarse cambiando el umbral de decisión según el contexto de aplicación.




Figura 14: Curva ROC en prueba. AUC= 0,9972. La curva se ubica prácticamente en la esquina superior izquierda, indicando discriminación casi perfecta. La diferencia entre AUC train (0.9914) y AUC test (0.9972) es marginal ($< 0,006$), lo que no aporta evidencia de sobreajuste.

AUC), sino que son además cuantitativamente precisas: una probabilidad predicha del 80 % corresponde efectivamente a que aproximadamente el 80 % de los jugadores en ese nivel se lesionan. Esta propiedad de calibración es esencial cuando las probabilidades predichas se utilizan directamente para

tomar decisiones de priorización clínica.




Figura 15: Curva Precision-Recall. Average Precision= 0,9973. La precisión permanece cercana a 1.0 para todo el rango de recall inferior a 0.95. La caída al final de la curva es la única concesión necesaria para alcanzar recall total (= 1,0).




Figura 16: Distribución bootstrap del AUC (1000 remuestras del conjunto de prueba). La distribución se concentra fuertemente en la zona alta del AUC, sin observaciones por debajo de 0.987. IC 95 % [0,993, 1,000].




Figura 17: Cuatro criterios de optimización del umbral. Todos convergen en $\tau^* = 0,48$. Las líneas verticales rojas señalan el óptimo; las grises, el umbral por defecto (0.50). El aplanamiento de todas las curvas en un rango amplio alrededor del óptimo implica robustez.




Figura 18: Curva de calibración (Brier Score= 0,024). Los puntos siguen de cerca la diagonal de calibración perfecta (línea gris). Las desviaciones más notables se observan en grupos intermedios (probabilidad $\approx 0,20$ y $\approx 0,70$), en menos de 5 pp.

Tabla 16: Deciles de la curva Gains. Los cuatro primeros alcanzan el techo teórico (Lift= 2,0), indicando que el modelo detecta el doble de lesiones que una selección aleatoria en ese rango.

Decil	<i>n</i>	Lesiones	Prob. media	% total	Lift
1	16	16	0.9998	20.0 %	2.00
2	16	16	0.9987	20.0 %	2.00
3	16	16	0.9955	20.0 %	2.00
4	16	16	0.9580	20.0 %	2.00
5	16	14	0.7013	17.5 %	1.75
6	16	2	0.1999	2.5 %	0.25
7-10	64	0	< 0,027	0.0 %	0.00

10.5. Curvas de Gains y Lift

Las curvas de Gains y Lift cuantifican la utilidad práctica del modelo en términos de priorización. El resultado más relevante: *con seguimiento al 40 % del equipo (deciles 1–4) se captura el 80 % de las lesiones potenciales*. Con seguimiento al 50 % se captura el 97.5 %, y con seguimiento al 60 % se captura la totalidad. La eficiencia de esta priorización tiene implicaciones presupuestales directas: el modelo permite orientar recursos médicos hacia los jugadores verdaderamente en riesgo, en lugar de distribuirlos uniformemente.

10.6. Validación cruzada 10-fold estratificada

La validación cruzada estratificada de 10 particiones evalúa el desempeño del modelo final en escenarios de generalización más realistas que la única partición train/test.

Procedimiento. Se utilizó el dataset completo de 800 jugadores, combinando los conjuntos original de entrenamiento (640) y prueba (160). El conjunto se dividió en 10 folds mutuamente excluyentes mediante *StratifiedKfold* [28] con semilla aleatoria 42. La estratificación garantiza que la proporción de lesionados (50 %) se mantiene en cada fold de validación y en cada conjunto de entrenamiento dentro del esquema CV. En cada iteración $k = 1, \dots, 10$:

1. Se entrena el modelo final (12 predictores + interacción Stress×Sleep) sobre los 720 jugadores de los 9 folds




Figura 19: Izquierda: curva de Gains. Derecha: curva de Lift. Con el 40 % de mayor riesgo se captura el 80 % de las lesiones; con el 60 % se captura el 100 %. El Lift se mantiene en su valor máximo teórico (2.0) hasta el decil 4, lo que refleja separación casi perfecta conseguida.

Tabla 17: Resultados por fold (10-fold CV estratificada, $n_{\text{val}} = 80$). La variabilidad entre folds es reducida; el rango de AUC va de 0.9725 a 1.0000, todo por encima de 0.97.

Fold	AUC	Accuracy	Brier	LogLoss
1	0.9938	0.9375	0.0375	0.1131
2	0.9725	0.8750	0.0853	0.2752
3	0.9912	0.9500	0.0388	0.1152
4	0.9756	0.9125	0.0741	0.2550
5	0.9994	0.9750	0.0178	0.0707
6	0.9944	0.9625	0.0295	0.1101
7	0.9931	0.9750	0.0250	0.1076
8	0.9912	0.9500	0.0334	0.1136
9	0.9962	0.9875	0.0170	0.0677
10	1.0000	0.9875	0.0218	0.0769
Media	0.9907	0.9513	0.0380	0.1305
DE	0.0093	0.0356	0.0234	0.0735
IC 95 % [0,985, 0,997][0,929, 0,973] [0,024, 0,053][0,085, 0,176]				

restantes, re-estimando todos los parámetros desde cero incluyendo el intercepto.

- Se predicen las probabilidades de lesión para los 80 jugadores del fold de validación.
- Se calculan AUC, accuracy (umbral 0.5), Brier Score y LogLoss sobre las predicciones fuera de muestra.

El proceso produce 10 estimaciones independientes de desempeño, cuya media y desviación estándar permiten construir intervalos de confianza del 95 % bajo la aproximación normal ($\bar{m} \pm 1,96 \text{ DE} / \sqrt{10}$).

El AUC promedio de 0,9907 (DE = 0,0093) con IC 95 % [0,985, 0,997] confirma que el desempeño del modelo es robusto a la composición particular de los datos de prueba. Los folds 2 y 4 presentaron un AUC ligeramente inferior (0,9725 y 0,9756, respectivamente), lo que es estadísticamente esperable en conjuntos de 80 observaciones donde la variación muestral puede producir particiones más difíciles. Aun en estos folds menos favorables, el AUC supera el 97 %. Los valores promedio de la validación cruzada son ligeramente inferiores a los del test simple original (AUC: 0.9907 vs. 0.9972; accuracy: 0.9513 vs. 0.9750; Brier: 0.0380

Tabla 18: Métricas de bondad de ajuste del modelo final.

Métrica	Valor
Log-Likelihood	-74,069
LLR p -valor	$1,51 \times 10^{-149}$
Pseudo- R^2 McFadden	0,833
Pseudo- R^2 Cox-Snell	0,685
Pseudo- R^2 Nagelkerke	0,913
Devianza nula (gl= 639)	887,23
Devianza residual (gl= 626)	148,14
Devianza explicada	83,30 %
AIC / BIC	176,14 / 238,60
AUC (prueba)	0,9972
AUC (CV 10-fold)	0,9907 $\pm$ 0,009
Brier Score (prueba)	0,0242

vs. 0.0242). Esta diferencia es esperada y demuestra que la partición original fue ligeramente más favorable que el promedio de particiones aleatorias, sin constituir un artefacto de sobreajuste.

10.7. Bondad de ajuste global

Los tres pseudo- R^2 ofrecen perspectivas complementarias sobre la calidad del ajuste. El **pseudo- R^2 de McFadden** [29] (0.833) mide la ganancia en log-verosimilitud respecto al modelo nulo: el modelo con predictores mejora la log-verosimilitud en un 83.3 % relativo. El **pseudo- R^2 de Cox-Snell** (0.685) se basa en la razón de verosimilitudes elevada a $2/n$ y tiene la limitación de no poder alcanzar 1 incluso con ajuste perfecto, lo que subestima sistemáticamente la calidad del ajuste. El **pseudo- R^2 de Nagelkerke** [30] (0.913) corrige esta restricción dividiendo el Cox-Snell por su valor máximo teórico, obteniendo una métrica comparable al R^2 clásico: el modelo explica el 91.3 % de la variabilidad de la respuesta en términos de Nagelkerke. La reducción del 83.3 % en la devianza (887,23 $\rightarrow$ 148,14) confirma que el conjunto de 13 predictores aporta una contribución masiva respecto al modelo sin covariables.




Figura 20: Distribución de AUC, Accuracy, Brier Score y LogLoss por fold. La baja variabilidad inter-fold, visible en la estrechez de los boxplots y la concentración de los puntos individuales (uno por fold), es consistente con estabilidad del modelo y no aporta evidencia de sobreajuste. El fold 2 es el de menor desempeño en todas las métricas simultáneamente, sugiriendo que esa partición contiene una proporción mayor de casos de difícil discriminación (jugadores atípicos).

11. COMPARACIÓN DE ESPECIFICACIONES

Para contextualizar el valor del protocolo metodológico aplicado, se comparan cuatro especificaciones progresivas del modelo sobre el mismo conjunto de prueba ($n = 160$): un modelo *naïve*, un modelo de literatura, el modelo reducido por AIC y el modelo final con interacción.

11.1. Definición de las especificaciones

El **modelo naïve** incorpora únicamente las variables que el discurso deportivo popular asocia intuitivamente con el riesgo de lesión: edad, partidos jugados la temporada anterior, horas de entrenamiento semanal y las tres dummies de posición (6 predictores en total). Representa la elección que haría un analista sin revisión de literatura ni análisis exploratorio previo [31], [32].

El **modelo literatura** incorpora las seis variables más citadas en la epidemiología deportiva clásica [5], [2], [7], [8], [9], [33]: nivel de estrés, horas de sueño, lesiones previas, adherencia al calentamiento, balance corporal y tiempo de reacción. Representa el estado del arte previo al análisis de datos: el conocimiento acumulado por la literatura especializada sin selección estadística formal adicional.

El **modelo reducido** es el obtenido mediante eliminación regresiva por AIC (Sección 6), con 12 predictores que incluyen las variables de literatura más el bloque neuromuscular identificado por el análisis exploratorio (sprint, agilidad, flexibilidad, fuerza de rodilla, nutrición).

El **modelo final** añade la interacción Stress×Sleep al modelo reducido (Sección 7), totalizando 13 parámetros más el intercepto.

11.2. Resultados

Tabla 19: Comparación de cuatro especificaciones sobre el conjunto de prueba ($n = 160$). El AIC se calcula sobre el conjunto de entrenamiento ($n = 640$).

Modelo	Vars.	AIC	AUC	Brier
Naïve	6	896.75	0.526	0.250
Literatura	6	322.37	0.957	0.088
Reducido (AIC)	12	178.97	0.997	0.024
Final+int.	13	176.14	0.997	0.024

11.2.1. Modelo naïve

El pseudo- R^2 de McFadden es de 0.005 y el LLR tiene $p = 0,612$: el conjunto de variables no mejora estadísticamente respecto al modelo nulo. En el conjunto de prueba, el AUC es de 0.526 (apenas por encima del aleatorio de 0.50) y el Brier Score es 0.250, prácticamente igual al máximo teórico bajo target balanceado. La accuracy del 48.8 % es incluso inferior al modelo nulo que predice siempre la clase mayoritaria (50 %). Este resultado confirma que la intuición futbolística no es un sustituto del análisis estadístico.

11.2.2. Modelo literatura

El salto respecto al naïve es dramático: el pseudo- R^2 sube a 0.652 y el LLR tiene $p < 10^{-121}$. Los seis coeficientes son altamente significativos ($p < 0,001$) con los signos esperados: el estrés lidera los factores de riesgo ($\hat{\beta} = +1,468$) y el balance los protectores ($\hat{\beta} = -1,338$). En prueba, el AUC es de 0.957 y la accuracy del 87.5 %. Sin embargo, el Brier Score de 0.088 es 3.6 veces peor que el del modelo reducido, y el bloque neuromuscular adicional (sprint, agilidad, flexibilidad, fuerza) permanece fuera de la especificación: ese es el costo de prescindir del análisis exploratorio.

11.2.3. Efecto de la selección por AIC y la interacción

La incorporación del bloque neuromuscular vía selección por AIC produce el segundo salto más grande: el AUC pasa de 0.957 a 0.997 (+0.040) y el Brier Score se reduce a menos de la tercera parte (0.088→0.024). La interacción Stress×Sleep reduce el AIC en 2.84 puntos adicionales y es significativa ($p = 0,029$); la ligera variación en métricas de prueba entre el modelo reducido y el final es atribuible a variación muestral en el test set de 160 observaciones, no a un deterioro real, como confirma la validación cruzada.

12. CONCLUSIONES

12.1. Síntesis de hallazgos

Este estudio identificó 12 predictores significativamente asociados con la probabilidad de lesión en jugadores profesionales de fútbol, agrupados en cuatro dimensiones:

- **Neuromuscular:** tiempo de reacción (OR = 3,84, AME= 4,65 pp), balance (OR = 0,23, AME= -5,07 pp), sprint (OR = 0,27, AME= -4,53 pp), agilidad (OR = 0,50, AME= -2,42 pp).
- **Psicológica:** estrés (OR = 3,59, AME= +4,42 pp).

Comparación: naïve → literatura → reducido → final+interacción




Figura 21: Izquierda: curvas de calibración de las cuatro especificaciones. El modelo naïve (rojo discontinuo) sigue la diagonal de manera errática, con probabilidades predichas acumuladas en 0.50 que reflejan su incapacidad discriminatoria. El modelo literatura (naranja) ya muestra una curva bien comportada pero con desviaciones sistemáticas en los deciles intermedios. Los modelos reducido y final se superponen prácticamente sobre la diagonal perfecta. Derecha: Brier Score comparativo. La reducción desde 0.250 (naïve) hasta 0.024 (final) representa una mejora del 90 % en calibración absoluta.




Figura 22: Curvas ROC de las cuatro especificaciones. El modelo naïve (rojo) apenas supera la diagonal aleatoria (AUC= 0,526). El modelo literatura (naranja) alcanza AUC= 0,957. Los modelos reducido (azul) y final (verde) se ubican prácticamente en la esquina superior izquierda (AUC= 0,997), con separación visual inapreciable entre ellos.

- **Clínica:** lesiones previas (OR=2,53, AME= +3,21 pp).
- **Hábitos:** sueño (OR = 0,31), nutrición (OR = 0,30), calentamiento (OR=0,25), flexibilidad (OR=0,36), fuerza de rodilla (OR=0,44).

La interacción significativa Stress×Sleep ($\hat{\beta} = -0,803$, $p = 0,029$) es el hallazgo más novedoso: los datos son consistentes con que el sueño adecuado se asocia con una reducción de la relación entre estrés y riesgo de lesión. Esta evidencia sugiere intervenciones sobre ambos factores simultáneamente, aunque se requiere validación prospectiva.

El desempeño predictivo es alto: AUC = 0,9972, Nagelkerke= 0,913, Brier= 0,024, accuracy 98.1 % bajo el umbral óptimo. Estas métricas deben interpretarse en el contexto de un dataset de laboratorio con separación fuerte entre clases, y podrían ser más modestas en datos observacionales con mayor heterogeneidad. La validación cruzada estratificada confirma la estabilidad (AUC_{CV} = 0,9907 ± 0,009), lo que es consistente con generalización fuera de muestra. La convergencia entre backward AIC y LASSO aporta evidencia de robustez en la selección de variables.

La comparación de especificaciones (Sección 11) cuantifica el valor añadido de cada etapa: el modelo naïve basado en intuición futbolística alcanza un AUC de apenas 0.526 y un Brier Score de 0.250; el modelo de literatura, con las seis variables clásicas de la epidemiología deportiva, sube a AUC= 0,957 y Brier= 0,088; y el modelo reducido por AIC con el bloque neuromuscular completo alcanza AUC= 0,997 y Brier= 0,024. Esta secuencia confirma que la revisión de literatura y el análisis exploratorio son los dos pasos de mayor impacto en el pipeline metodológico.

12.2. Limitaciones

1. **Diseño observacional y ausencia de causalidad.** El diseño de corte transversal permite estimar asociaciones condicionales, no efectos causales. Todas las interpretaciones de este trabajo son asociativas. Afirmaciones sobre mecanismos (por ejemplo, el rol del sueño o el estrés) son hipótesis teóricas consistentes con los datos, no inferencias causales establecidas.
2. **Posible artificialidad del dataset.** La variable respuesta está perfectamente balanceada (50 %/50 %), la separación entre clases es excepcionalmente alta, y todos los VIF son muy bajos. Estos patrones son infrecuentes en datos observacionales reales y sugieren que el dataset podría

haber sido generado sintéticamente o seleccionado de forma muy controlada. Si es así, las métricas de desempeño (AUC, Brier) podrían estar infladas respecto a lo esperable en datos clínicos reales, y los resultados deben interpretarse con cautela.

3. **Sesgo post-selección (stepwise + inferencia).** La eliminación regresiva por AIC es un procedimiento adaptativo: las variables finales y sus coeficientes son seleccionados después de examinar los datos. Bajo la teoría clásica, esto invalida parcialmente los p -valores e IC, que tienden a ser optimistas. La validación cruzada y el LASSO mitigan —pero no eliminan— este sesgo. Los valores exactos de p e IC reportados deben interpretarse como evidencia orientativa, no como inferencias con cobertura garantizada al 95 %.
4. **Variables omitidas.** Técnica individual, carga diferencial por nivel del rival, calidad del terreno, condiciones climáticas, fatiga acumulada y eventos de contacto fortuito no están representados. Su ausencia constituye la explicación más probable de los 10 casos clínicamente atípicos y puede generar confusión residual en las asociaciones estimadas.
5. **Quasi-separación parcial y extrapolación.** En torno al 12 % de observaciones el modelo predice con probabilidades extremas ($< 0,01$ o $> 0,99$). Esto sugiere quasi-separación, situación en la que los coeficientes pueden estar inflados y los errores estándar son poco confiables. Las predicciones en ese rango deben tratarse con precaución adicional.
6. **Ausencia de validación externa y transversalidad.** Los resultados se derivan de una única muestra, sin replicación en poblaciones independientes (otras ligas, rangos etarios, niveles de competencia). Las mediciones son puntuales y no capturan dinámicas longitudinales ni la trayectoria intra-temporada del jugador. La validación cruzada interna mitiga el riesgo de sobreajuste al conjunto específico de datos, pero no es sustituto de validación prospectiva en nuevas poblaciones.
7. **Tamaño muestral y poder estadístico.** Con $n = 800$ registros el estudio se encuentra en el límite inferior de las guías de eventos por variable (EPV) para regresión logística [12]. El modelo final tiene 13 parámetros libres, lo que implica $EPV \approx 30$ (usando los 400 casos positivos), razonable pero no holgado. En particular, los efectos de interacción y los coeficientes de variables con menor prevalencia relativa (Warmup, una variable binaria) tienen intervalos de confianza amplios que reflejan esta limitación. Una muestra de $n \geq 2,000$ observaciones permitiría detectar efectos más pequeños con potencia adecuada y reducir el riesgo de quasi-separación.

12.3. Extensiones propuestas

1. Modelos jerárquicos multinivel (jugador $\rightarrow$ equipo $\rightarrow$ liga) mediante GLMM para capturar heterogeneidad contextual.
2. Modelos de supervivencia (Cox, Weibull) para modelar el tiempo hasta la primera lesión incorporando censura.
3. Métodos de ML interpretable (SHAP, LIME) para capturar interacciones de orden superior sin sacrificar explicabilidad.

4. Validación externa prospectiva en poblaciones independientes.
5. Replicación del análisis de comparación de especificaciones con datos de ligas independientes, para evaluar si la brecha naïve $\rightarrow$ literatura $\rightarrow$ datos se mantiene en otros contextos poblacionales.

12.4. Recomendaciones operativas

1. **Monitorear estrés y sueño simultáneamente:** la interacción significativa sugiere que intervenciones sobre ambos factores conjuntamente podrían ser más efectivas que acciones aisladas, aunque se requiere validación prospectiva del efecto causal.
2. **Considerar el calentamiento sistemático:** la asociación con menor riesgo sugiere una intervención de alta relación beneficio-coste entre los factores modificables identificados.
3. **Seguimiento intensivo** para jugadores con $\text{Previous_Injury} \geq 3$ y Reaction_Time superior al percentil 75, como perfil de riesgo observacionalmente elevado.
4. **Evaluaciones periódicas** de balance y tiempo de reacción como indicadores de seguimiento, consistentes con su asociación con riesgo.
5. **Priorización clínica:** el 40 % de mayor probabilidad predicha concentra el 80 % de las lesiones observadas; con el 60 % se captura la totalidad.
6. **Herramienta de apoyo clínico:** el modelo está disponible como aplicación interactiva en <https://mel-lesiones.streamlit.app/>, donde es posible ingresar el perfil de un jugador y obtener su probabilidad de lesión y plan de intervención priorizado.

DECLARACIÓN DE USO DE IA GENERATIVA

De acuerdo con la política de integridad académica del curso IIND-4100, se declara que **Claude (Anthropic)** se empleó para revisar la coherencia metodológica del análisis y obtener retroalimentación sobre la estructura del informe. **Copilot/ChatGPT** se usaron para depurar sintaxis Python. Las decisiones de modelado, interpretación y conclusiones son de autoría propia en los términos del curso IIND-4100.

REFERENCIAS

- [1] T. Soligard, M. Schwellnus, J. M. Alonso *et al.*, "How much is too much? (Part 1) International Olympic Committee consensus statement on load in sport and risk of injury," *British Journal of Sports Medicine*, vol. 50, no. 17, pp. 1030–1041, 2016.
- [2] W. H. Meeuwisse, H. Tyreman, B. Hagel, and C. Emery, "A dynamic model of etiology in sport injury: the recursive nature of risk and causation," *Clinical Journal of Sport Medicine*, vol. 17, no. 3, pp. 215–219, 2007.
- [3] P. McCullagh and J. A. Nelder, *Generalized Linear Models*, 2nd ed. London: Chapman & Hall, 1989.
- [4] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. Hoboken, NJ: Wiley, 2013.
- [5] M. B. Anderson and J. M. Williams, "A model of stress and athletic injury: prediction and prevention," *Journal of Sport and Exercise Psychology*, vol. 10, no. 3, pp. 294–306, 1988.
- [6] T. J. Gabbett, "The training–injury prevention paradox: should athletes be training smarter and harder?" *British Journal of Sports Medicine*, vol. 50, no. 5, pp. 273–280, 2016.

- [7] M. D. Milewski, D. L. Skaggs, G. A. Bishop *et al.*, "Chronic lack of sleep is associated with increased sports injuries in adolescent athletes," *Journal of Pediatric Orthopaedics*, vol. 34, no. 2, pp. 129–133, 2014.
- [8] N. van Dyk, R. Bahr, A. F. Burnett *et al.*, "A comprehensive strength testing protocol offers no clinical value in predicting risk of hamstring injury: a prospective cohort study of 413 professional football players," *British Journal of Sports Medicine*, vol. 51, no. 23, pp. 1695–1702, 2017.
- [9] A. Ivarsson, U. Johnson, M. B. Andersen *et al.*, "Psychosocial factors and sport injuries: meta-analyses for prediction and prevention," *Sports Medicine*, vol. 47, no. 2, pp. 353–365, 2017.
- [10] Y. Hong, "University football injury prediction dataset," Kaggle, 2024. [Online]. Available: <https://www.kaggle.com/datasets/yuanchunhong/university-football-injury-prediction-dataset>
- [11] Y. Hong *et al.*, "SHAP-based interpretable machine learning for injury risk prediction in university football players: a multi-dimensional data analysis approach," *Scientific Reports*, vol. 15, 2025.
- [12] P. Peduzzi, J. Concato, E. Kemper, T. R. Holford, and A. R. Feinstein, "A simulation study of the number of events per variable in logistic regression analysis," *Journal of Clinical Epidemiology*, vol. 49, no. 12, pp. 1373–1379, 1996.
- [13] D. A. Belsley, E. Kuh, and R. E. Welsch, *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. New York: Wiley, 1980.
- [14] A. J. Miller, "Selection of subsets of regression variables," *Journal of the Royal Statistical Society: Series A*, vol. 147, no. 3, pp. 389–425, 1984.
- [15] H. Akaike, "A new look at the statistical model identification," *IEEE Transactions on Automatic Control*, vol. 19, no. 6, pp. 716–723, 1974.
- [16] H. Leeb and B. M. Pötscher, "Model selection and inference: facts and fiction," *Econometric Theory*, vol. 21, no. 1, pp. 21–59, 2005.
- [17] J. Taylor and R. J. Tibshirani, "Statistical learning and selective inference," *Proceedings of the National Academy of Sciences*, vol. 112, no. 25, pp. 7629–7634, 2015.
- [18] R. Tibshirani, "Regression shrinkage and selection via the lasso," *Journal of the Royal Statistical Society: Series B*, vol. 58, no. 1, pp. 267–288, 1996.
- [19] K. P. Burnham and D. R. Anderson, *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach*, 2nd ed. New York: Springer, 2002.
- [20] G. E. P. Box and P. W. Tidwell, "Transformation of the independent variables," *Technometrics*, vol. 4, no. 4, pp. 531–550, 1962.
- [21] D. Pregibon, "Goodness of link tests for generalized linear models," *Applied Statistics*, vol. 29, no. 1, pp. 15–24, 1980.
- [22] T. A. Stukel, "Generalized logistic models," *Journal of the American Statistical Association*, vol. 83, no. 402, pp. 426–431, 1988.
- [23] J. B. Ramsey, "Tests for specification errors in classical linear least-squares regression analysis," *Journal of the Royal Statistical Society: Series B*, vol. 31, no. 2, pp. 350–371, 1969.
- [24] J. A. Hanley and B. J. McNeil, "The meaning and use of the area under a receiver operating characteristic (ROC) curve," *Radiology*, vol. 143, no. 1, pp. 29–36, 1982.
- [25] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [26] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1994.
- [27] G. W. Brier, "Verification of forecasts expressed in terms of probability," *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950.
- [28] M. Stone, "Cross-validatory choice and assessment of statistical predictions," *Journal of the Royal Statistical Society: Series B*, vol. 36, no. 2, pp. 111–147, 1974.
- [29] D. McFadden, "Conditional logit analysis of qualitative choice behavior," pp. 105–142, 1974.
- [30] N. J. D. Nagelkerke, "A note on a general definition of the coefficient of determination," *Biometrika*, vol. 78, no. 3, pp. 691–692, 1991.
- [31] S. Drawer and C. W. Fuller, "Evaluating the level of injury in english professional football using a risk based assessment process," *British Journal of Sports Medicine*, vol. 36, no. 6, pp. 446–451, 2002.
- [32] J. Ekstrand, M. Häggglund, and M. Waldén, "Injury incidence and injury patterns in professional football: the UEFA injury study," *British Journal of Sports Medicine*, vol. 45, no. 7, pp. 553–558, 2011.
- [33] M. Waldén, M. Häggglund, H. Magnusson, and J. Ekstrand, "Anterior cruciate ligament injury in elite football: a prospective three-cohort study," *Knee Surgery, Sports Traumatology, Arthroscopy*, vol. 19, no. 1, pp. 11–19, 2011.