

Determinantes de las lesiones en jugadores profesionales

Regresión logística binaria

Samuel Arbeláez Abraham Bohorquez

Profesora: Alejandra Tabares Pozos


IIND-4100 — Modelos Estadísticos Lineales
Universidad de los Andes, Bogotá

Mayo 2026

- 1 Motivación
- 2 Datos y EDA
- 3 Especificación y estimación
- 4 Multicolinealidad y selección
- 5 Interacción Stress $\times$ Sleep
- 6 Resultados: OR y AME
- 7 Comparación de modelos
- 8 Validación predictiva
- 9 Conclusiones

¿Por qué predecir lesiones?

- **150–200 días-jugador** perdidos por temporada en ligas europeas.
- Costo directo > **10 millones de euros** por club y temporada.
- Las lesiones son **multifactoriales**: física, psicología, clínica y hábitos interactúan.



Pregunta de investigación

¿Cuáles factores determinan la probabilidad de lesión en la temporada siguiente, y con qué **magnitud** opera cada uno, controlando por los demás?

Hipótesis con dirección teórica

Sustentadas en literatura biomecánica

	Predictor	Signo
$H_1^{(1)}$	Estrés	$\beta > 0$
$H_1^{(2)}$	Sueño	$\beta < 0$
$H_1^{(3)}$	Les. previas	$\beta > 0$
$H_1^{(4)}$	Balance	$\beta < 0$
$H_1^{(5)}$	Calentamiento	$\beta < 0$

Resto de variables: contrastes bilaterales.

Objetivos específicos

- 1 Identificar variables significativas en contexto **multivariado**.
- 2 Cuantificar magnitudes vía **OR** y **AME**.
- 3 Validar todos los supuestos del GLM.
- 4 Evaluar desempeño con **CV 10-fold estratificada**.
- 5 Comparar **Backward AIC** vs. **LASSO**.

El dataset

Dominio	Variables
Antropométrico	Edad, IMC , Peso, Talla
Carga	Entrenamiento, Partidos, Lesiones previas
Físico	Rodilla, Isquiotibiales, Reacción, Balance, Sprint, Agilidad
Hábitos	Sueño, Nutrición, Calentamiento
Posición	Defensa, Medio, Delantero, Portero
Respuesta	Injury_Next_Season — binaria (0/1)

50 % 50 %

Balance perfecto

Preprocesamiento

- Eliminar Talla y Peso por colinealidad con IMC ($r = 0.85$) $\rightarrow$ 17 variables
- One-hot encoding: Position
- Estandarizar 14 continuas ($\mu=0$, $\sigma=1$) solo sobre el train
- División train/test: 640/160 (estratificada, 50/50 en ambas)

Variables no significativas en bivariado

incluidas de todas formas en el modelo

- **Posición de juego** ($p = 0.49$): no discrimina en bivariado, pero puede tener aporte en contexto multivariado
- **BMI, Edad, Partidos**: correlación baja con el target ($|r| < 0.05$), incluidas para que la selección automática evalúe su aporte

Modelo GLM Bernoulli-logit


Especificación formal

$$Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(\mu_i)$$

$$g(\mu_i) = \log\left(\frac{\mu_i}{1 - \mu_i}\right) = \mathbf{x}_i^\top \boldsymbol{\beta}$$

Modelo base — Completo

Log-verosimilitud	-75.63
McFadden R^2	0.830
AIC	189.27
BIC	274.03
LLR p -valor	$< 10^{-144}$



11 de 18 variables significativas al 5 %.

Diagnóstico de multicolinealidad

Número de condición κ

$$\kappa = 5.46 < 10$$

$$\lambda_{\max} = 1860.5, \quad \lambda_{\min} = 62.5$$

Sin multicolinealidad relevante

Factor de inflación de varianza (VIF)

Umbral de preocupación: $VIF > 5$

Variable	VIF
Warmup_Adherence	2.08
Position_Midf.	1.45
Stress_Level	1.29
Balance_Score	1.26
Sleep_Hours	1.25
Reaction_Time	1.22
Knee_Strength	1.21
Hamstring_Flex	1.17
Nutrition	1.14
<i>resto</i>	< 1.05

Máximo VIF = 2.08.


Selección de variables: Backward AIC

			Prueba LRT (base vs. reducido)		
Paso	Variable eliminada	AIC	LR = 1.71, gl = 6, p = 0.944		
0	— (modelo base)	189.27			
1	Position_Forward	187.32			
2	Matches_Season	185.40			
3	Position_Midfielder	183.54	Variables	18	12
4	BMI	181.69	AIC	189.27	178.97
5	Position_Goalkeeper	179.94	BIC	274.03	236.97
6	Age	178.97	McFadden R^2	0.830	0.828

Modelos estadísticamente equivalentes ($p = 0.944$). Se elige el **reducido** por **parsimonia**.




Component-Residual plots

Component-Residual plots — diagnóstico visual de linealidad del logit



La curva LOWESS sigue la recta lineal en los **11 predictores continuos**. La relación de cada variable con el logit es lineal: no se requieren transformaciones. Las pruebas formales lo confirman.


Análisis de residuos



Tipo	Media	DE	Outliers
Pearson	-0.02	0.63	13 (2.0 %)
Devianza	+0.00	0.49	7 (1.1 %)
Anscombe	+0.01	0.81	9 (1.4 %)




Proporciones inferiores al 5 % esperado bajo buen ajuste.

Half-normal plot



0 % de los residuos cae fuera del envelope al 95 % (100 réplicas Monte Carlo).
Ajuste excelente.

Observaciones influyentes



Métrica	Umbral	N
Cook D_i	$> 4/n$	45
Leverage h_{ii}	$> 2k/n$	110
$ r_i > 2$	—	15
3 alarmas	—	10


Sensibilidad: al excluir los 10 críticos, todos los coeficientes preservan su signo. Se conserva el modelo original.

Evaluación de interacciones

Interacción	$\hat{\beta}$	p	ΔAIC
Stress × Sleep	−0.803	0.029	−2.84
PrevInj×KneeStr	−0.195	0.463	+1.46
Warmup×React	−0.020	0.968	+2.00

Solo **Stress**×**Sleep** es significativa ($p = 0.029$, $\Delta\text{AIC} = -2.84$).


¿Por qué importa la interacción?



- **Sueño deficiente:** el estrés lleva la probabilidad al **100 %**.
- **Sueño adecuado:** la curva se aplan, el estrés pierde impacto.
- Intervenir en sueño tiene **dobles efecto**: reduce riesgo directo y modera el estrés.

	Aditivo	+Interacc.
AIC	178.97	176.14
R ² McF	0.828	0.833

Forest plot de Odds Ratios




Factores de riesgo (OR > 1)

- **Reaction_Time**: OR = 3.84
- **Stress_Level**: OR = 3.59
- **Previous_Injury**: OR = 2.53
- **Training_Hours**: OR = 1.78

Factores protectores (OR < 1)

- **Balance_Score**: OR = 0.23
- **Warmup**: OR = 0.25
- **Sprint_Speed**: OR = 0.27
- **Nutrition**: OR = 0.30
- **Sleep_Hours**: OR = 0.31
- **Hamstring**: OR = 0.36

Efectos marginales promedio (AME)



El AME mide el cambio promedio en probabilidad de lesión ante 1 DE adicional en el predictor.


Top factores de riesgo

- **Reaction_Time**: +4.65 pp
- **Stress_Level**: +4.42 pp
- **Previous_Inj**: +3.21 pp

Top factores protectores

- **Balance**: -5.07 pp
- **Warmup**: -4.84 pp
- **Sprint**: -4.53 pp

Matriz de confusión y métricas





Solo **4 errores** sobre 160 jugadores:
1 falso positivo + 3 falsos negativos.

Métrica	Thr 0.50	Thr 0.48
Accuracy	0.9750	0.9813
Precision	0.9872	0.9873
Recall	0.9625	0.9750
F1-Score	0.9747	0.9811
MCC	—	0.9626
AUC	0.9972	
Brier Score	0.0242	

Comparación de especificaciones: calibración


Comparación: naïve → literatura → reducido → final+interacción



Brier Score por modelo

Escala: 0 (perfecto) a 0.25 (aleatorio).

Comparación de especificaciones: discriminación



Curvas ROC — 4 modelos

- Naïve**
AUC = 0.526 — apenas sobre la diagonal aleatoria
- Literatura**
AUC = 0.957 — literatura clásica ya discrimina bien
- Reducido**
AUC = 0.997 — bloque neuromuscular cierra la brecha
- Final+int.**
AUC = 0.997 — superposición visual con el reducido

12 predictores en 4 dimensiones

Neuromuscular

Reaction_Time

OR = 3.84

Balance OR = 0.23

Psicológica

Stress OR = 3.59

Clínica

Previous_Injury

OR = 2.53

Hábitos

**Sleep, Nutrition,
Warmup**

Recomendaciones

- 1 **Estrés + sueño:** doble efecto preventivo.
- 2 **Calentamiento:** mayor retorno marginal.
- 3 Seguimiento con **historial cargado**.
- 4 **Balance y Reaction_Time:** indicadores tempranos.
- 5 Top **40 %** capta el **80 %** de lesiones.

Limitaciones

- Variables omitidas: técnica, terreno, contacto.
- Asociación, no causalidad.
- Sin validación externa.

Trabajo futuro

- Modelos jerárquicos multinivel.
- Modelos de supervivencia.
- ML con SHAP/LIME + validación externa.

Proyecto Final — IIND-4100 — Mayo 2026

Samuel Arbeláez ▪ Abraham Bohorquez


Universidad de los Andes, Departamento de Ingeniería Industrial

<https://mel-lesiones.streamlit.app/>

Tabla consolidada — modelo final

Variable	$\hat{\beta}$	OR	IC 95 %	AME (pp)	p
<i>Factores de riesgo</i>					
Reaction_Time	+1.35	3.84	[2.32, 6.35]	+4.65	< 0.001
Stress_Level	+1.28	3.59	[2.10, 6.15]	+4.42	< 0.001
Previous_Injury	+0.93	2.53	[1.57, 4.10]	+3.21	< 0.001
Training_Hrs	+0.39	1.48	[0.93, 2.34]	+1.35	0.095
<i>Factores protectores</i>					
Agility_Score	-0.70	0.50	[0.31, 0.80]	-2.42	0.004
Knee_Strength	-0.83	0.44	[0.27, 0.71]	-2.87	0.001
Hamstring_Flex	-1.03	0.36	[0.22, 0.57]	-3.55	< 0.001
Sleep_Hours	-1.17	0.31	[0.18, 0.52]	-4.05	< 0.001
Nutrition	-1.20	0.30	[0.18, 0.51]	-4.15	< 0.001
Sprint_Speed	-1.31	0.27	[0.16, 0.47]	-4.53	< 0.001
Warmup	-1.40	0.25	[0.10, 0.63]	-4.84	0.003
Balance_Score	-1.47	0.23	[0.13, 0.42]	-5.07	< 0.001
<i>Interacción</i>					
Stress_Level	0.89	0.45	[0.22, 0.92]	-0.020	0.020

Backward AIC vs. LASSO — coeficientes



Los signos coinciden en todos los predictores comunes. LASSO produce *shrinkage* adicional (penalización L1, $\lambda^* = 2.56$).

Backward AIC vs. LASSO — criterios

Métrica	Base	Backward	LASSO
Variables	18	12	13
AIC	189.27	178.97	187.1
BIC	274.03	236.97	250.1
AUC (test)	—	0.9972	0.9972
Brier	—	0.0242	0.0242

Conclusión

AIC y BIC favorecen el modelo **Backward**.

Los signos son robustos: ambos métodos convergen en la misma estructura.

Las diferencias de AUC (0.0006) y Brier (0.0002) son despreciables.

12 variables en común:

Agility, Balance, Hamstring, Knee, Nutrition, Previous.Inj, Reaction, Sleep, Sprint, Stress, Training_Hrs, Warmup

Solo en LASSO: Age ($\hat{\beta} = 0.052$)

Solo en Backward: ninguna

Ambos métodos descartan las mismas 5 variables: Position{Fwd, Mid, GK}, BMI y Matches_Past_Season.

LASSO retiene Age con coeficiente residual de 0.052, que el backward eliminó en el último paso.

Modelo reducido — coeficientes

Variable	$\hat{\beta}$	SE	p
(Intercepto)	+0.81	0.38	0.030
Training_Hrs	+0.39	0.23	0.095
Previous_Inj	+0.93	0.25	< 0.001
Knee_Strength	-0.83	0.25	0.001
Hamstring_Flex	-1.03	0.24	< 0.001
Reaction_Time	+1.35	0.26	< 0.001
Balance_Score	-1.47	0.30	< 0.001
Sprint_Speed	-1.31	0.28	< 0.001
Agility_Score	-0.70	0.24	0.004
Sleep_Hours	-1.17	0.27	< 0.001
Stress_Level	+1.28	0.27	< 0.001
Nutrition	-1.20	0.27	< 0.001
Warmup	-1.40	0.48	0.003


Rojo: factor de riesgo ($\hat{\beta} > 0$)
Verde: factor protector ($\hat{\beta} < 0$)
Training_Hrs: marginal
($p = 0.095$)

Métricas

McFadden R^2	0.828
AIC	178.97
BIC	236.97
LLR p	< 10^{-149}

Optimización del threshold

Métricas vs threshold de clasificación




¿Cómo se encontró 0.48?

- Se evaluaron todos los thresholds entre 0.05 y 0.95.
- Cuatro criterios independientes: Youden J, F1, MCC y Cohen κ .
- Los **cuatro coinciden** en $\tau^* = 0.48$.

Las probabilidades predichas son bimodales: $Q1 = 0.005$, $Q3 = 0.996$. El modelo no duda: predice cerca de 0 o cerca de 1.

Bootstrap del AUC





1 000 remuestras bootstrap del test

Estadístico	Valor
Media	0.9972
Desv. est.	0.0021
IC 95 %	[0.993, 1.000]

La estimación es insesgada.
Ningún valor por debajo de 0.987.
La distribución se concentra fuertemente cerca de 1.

Curvas Gains y Lift



Top %	Capturado	Lift
20 %	40 %	2.00
40 %	80 %	2.00
50 %	97.5 %	1.95
60 %	100 %	1.00


Supervisar al **40 %** de jugadores de mayor riesgo predicho captura el **80 %** de las lesiones potenciales.

Lift máximo = 2.0: techo teórico para target balanceado.

Top correlaciones con el target

Variable	$ r $
Stress_Level	0.530
Sleep_Hours	0.511
Balance_Score	0.495
Reaction_Time	0.471
Sprint_Speed	0.471
Knee_Strength	0.455
Peso-IMC (colineal)	0.850


Validación cruzada 10-fold estratificada



AUC test vs. CV: 0.997 vs. 0.991 ($\Delta=0.006$). Baja variabilidad entre folds.
Sin sobreajuste.

Métrica	Media	IC 95 %
AUC	0.991	[0.985, 0.997]
Accuracy	0.951	[0.929, 0.973]
Brier	0.038	[0.024, 0.053]


Curvas ROC y Precision-Recall



AUC = 0.9972.

AUC train: 0.9914 ($\Delta = 0.006$).

Sin signos de sobreajuste.



Average Precision = 0.9973.

Alta precisión en todo el rango
de recall.

Bondad de ajuste global

Métrica	Valor
McFadden R^2	0.833
Nagelkerke R^2	0.913
Dev. explicada	83.3 %
AIC	176.14
AUC (prueba)	0.9972
AUC (CV)	0.991 ± 0.009
Brier Score	0.0242

Hipótesis evaluadas

- ✓ $H_1^{(1)}$ Estrés ↑ riesgo $p < 0.001$
- ✓ $H_1^{(2)}$ Sueño ↓ riesgo $p < 0.001$
- ✓ $H_1^{(3)}$ Les. prev. ↑ riesgo $p < 0.001$
- ✓ $H_1^{(4)}$ Balance ↓ riesgo $p < 0.001$
- ✓ $H_1^{(5)}$ Warmup ↓ riesgo $p = 0.003$

Todas confirmadas en la dirección esperada.

Hallazgo distintivo

La interacción **Stress**×**Sleep**: el sueño amortigua el estrés con doble efecto preventivo.